
HENRIQUE BOTELHO DA MOTTA

Modelagem da decomposição térmica de alúmen de potássio utilizando redes neurais artificiais


Amanda Lemette

Orientadora

Isabelle Valim

Co-orientadora

Introdução



Nutrientes: Potássio

KCl

└─ K₂SO₄

40.920 ton
importadas em
2013

Introdução


- Alternativa:



- ✓ Abundante no Brasil
- ✓ Presença significativa de K


Introdução

- Processo de obtenção:



Introdução

- Destrinchando a decomposição térmica do alúmen :



Introdução

- Óxido de alumínio
 - Segundo metal mais utilizado no mundo
 - Usualmente obtido através do processo Bayer de beneficiação
 - Geração de “lama vermelha”
 - Tóxico
 - Contamina solos
 - Afeta a qualidade da água

Introdução


- Para viabilizar a utilização deste processo é importante estudar mais a fundo a decomposição térmica
 - A Análise Termogravimétrica (TGA) possibilita este estudo em escala laboratorial, reproduzindo as condições da decomposição térmica
 - TGAs fornecem uma grande quantidade de dados
 - Para interpretar tais resultados e entender mais sobre o processo é importante modelá-los
 - A modelagem permite:
 - Analisar o comportamento do composto ao longo do processo
 - Testar mecanismos possíveis
 - Auxiliar no escalonamento do processo
 - Testar condições de segurança

Introdução

- Alternativas para modelagem da TGA:
 - Métodos gráficos
 - Ozawa
 - Kissinger
 - Modelagem fenomenológica baseada em balanço de massa
 - Redes Neurais Artificiais


Introdução

- Redes Neurais:
 - Simulações matemáticas baseadas no funcionamento de sistemas neurológicos
 - Processa grandes quantidades de dados
 - Não necessita de simplificações
 - Não necessita de suposições do funcionamento da reação
 - Fornecem equações simples para predição do processo



Introdução

Algoritmo de treinamento




Objetivo



- Estudar diferentes topologias de redes neurais
- Avaliar os modelos obtidos
- Assegurar modelos sem gasto computacional desnecessário
- Garantir precisão dos modelos
- Avaliar escolha de variáveis de entrada

Metodologia


- Dados experimentais utilizados de (Nofal et al., 2019)
 - Análise feita com três taxas de aquecimento diferentes (10, 15 e 20°C min⁻¹)
 - Modelagem fenomenológica baseada em balanço de massa
 - Variáveis: tempo, temperatura, perda de massa percentual e DTG
 - XRD no início e fim do processo




Metodologia



Metodologia



Metodologia



Metodologia


- Matlab R2019a: Funcionamento do software
 - Treinamento supervisionado
 - Input e Output
 - Autoavaliação por comparação
 - Correção dos parâmetros
 - Dados de teste para avaliar modelo final (SSE e R^2)

Metodologia

- Algoritmos de treinamento
 - Variações do Backpropagation
 - Atualizações ao longo do processo dos pesos e bias
 - Levenberg-Marquadt – *trainlm*
 - Regularização Bayesiana – *trainbr*
 - Secantes de um passo - *trainoss*
 - Gradiente de momento descendente – *traingdx*
 - Gradiente conjugado com Power-Beale – *traincgb*
- Funções de ativação
 - Realizam o processamento da informação
 - Funções utilizadas: tangente hiperbólica, tangente logística e *purelin*

$$\text{purelin}(x) = x \qquad \text{tansig}(x) = \frac{2}{1 + e^{-2x}} - 1 \qquad \text{logsig}(x) = \frac{1}{1 + e^{-x}}$$

Metodologia




Metodologia

Modelo	Presença de carvão	Variáveis de Input	Variáveis de Output
1	Não	Temperatura	Perda de massa
2	Não	Temperatura e DTG	Perda de massa
3	Sim	Temperatura	Perda de massa
4	Sim	Temperatura e DTG	Perda de massa

Modelo	Algoritmo de Treinamento	Neurônios Camada Interna 1	Função de Ativação Camada Interna 1	Neurônios Camada Interna 2	Função de Ativação Camada Interna 2	SSE	R ² Treino	R ² Teste
1	trainlm	10	logsig	-	-	0.0436	0.99992	0.99992
	trainbr	10	logsig	-	-	0.0497	0.99993	0.99993
	trainoss	10	logsig	-	-	0.3390	0.99939	0.99939
	traingdx	10	logsig	-	-	2.0100	0.99635	0.99636
	traincgb	10	logsig	-	-	0.1410	0.99974	0.99974
	trainlm	10	logsig	10	logsig	0.0246	0.99996	0.99996
2	trainlm	10	tansig	-	-	0.0475	0.99991	0.99992
	traingdx	10	tansig	-	-	3.9100	0.99301	0.99302
	traingdx	10	logsig	-	-	21.3000	0.96067	0.96135
	trainlm	30	tansig	-	-	0.0377	0.99993	0.99993
	trainlm	5	tansig	5	tansig	0.0411	0.99993	0.99993
	trainlm	10	logsig	10	tansig	0.0429	0.99993	0.99993
3	trainlm	5	tansig	5	tansig	0.0072	0.99998	0.99998
	trainlm	5	logsig	5	logsig	0.0271	0.99995	0.99995
	trainoss	10	tansig	-	-	0.0540	0.99989	0.99989
	trainoss	10	logsig	-	-	0.0810	0.99983	0.99984
	trainbr	5	logsig	5	logsig	0.0165	0.99997	0.99997
	trainbr	5	tansig	5	tansig	0.0169	0.99997	0.99998
4	trainbr	5	tansig	5	tansig	0.0068	0.99999	0.99999
	trainbr	5	logsig	-	-	0.0272	0.99996	0.99995
	trainbr	10	logsig	-	-	0.0277	0.99996	0.99996
	trainoss	10	tansig	-	-	1.9200	0.99653	0.99664
	trainoss	10	logsig	-	-	2.2800	0.99594	0.99634
	trainbr	3	tansig	3	tansig	0.0320	0.99995	0.99995


Resultados e Discussões

- Sem carvão
 - Modelo 1 (sem carvão, temperatura input e perda de massa como output)
 - 1 variável de input, 1 camada intermediária, 10 neurônios, função de ativação *logsig* e algoritmo de treinamento *trainlm*




$$R^2 = 0,99992$$

$$SSE = 0,0436$$




Resultados e Discussões

- Com carvão
 - Modelo 3 (com carvão, temperatura input e perda de massa como output)
 - 1 variável de input, 2 camadas intermediárias, ambas com 5 neurônios e *tansig* como função de ativação e algoritmo de treinamento *trainlm*



$$R^2 = 0,99998$$

$$SSE = 0,0072$$



Resultados e Discussões

- Sem carvão

$$y = \sum_{j=1}^n \left(\sum_{i=1}^m w_{ji} x \right) + b_j$$

Função: *logsig*

j	Weights		Bias	
	Input Layer	Hidden Layer	Input Layer	Hidden Layer
1	31.0197	-0.0741	-29.5607	-0.1556
2	-29.0202	0.2208	18.9633	-
3	24.9302	0.0138	-22.8158	-
4	46.0803	-0.7776	-20.3517	-
5	-20.7458	0.8545	7.5354	-
6	-26.4373	0.0333	3.7476	-
7	-28.6552	0.0065	-6.5060	-
8	-27.7250	0.0019	-16.0370	-
9	-28.0510	0.0157	-21.3497	-
10	-28.8919	0.0243	-26.8604	-

Resultados e Discussões

- Com carvão

$$y = \sum_{j=1}^n \left(\sum_{i=1}^m w_{ji} x \right) + b_j$$

Função: *tansig*

j	Weights							Bias		
	Input Layer	Hidden Layer 1					Hidden Layer 2	Input Layer	Hidden Layer 1	Hidden Layer 2
1	13.0746	24.8766	-0.5464	0.9860	-1.0002	-1.1952	-0.2227	-12.8833	-1.6027	0.0052
2	-12.5559	-9.0075	4.8639	-1.6268	0.5500	-3.2874	1.1900	1.0414	-0.7067	-
3	5.5487	-0.9959	-1.7366	2.9763	2.3277	-0.2380	0.4608	-2.1499	-0.1412	-
4	-3.7292	-0.2176	-2.3185	1.4144	0.8874	4.0350	-0.2054	-1.4004	1.7416	-
5	6.5936	-31.5366	0.2316	1.6878	-1.1267	-4.0596	-0.2047	6.3463	-12.8870	-

Resultados e Discussões

Modelo	Algoritmo de Treinamento	Neurônios Camada Interna 1	Função de Ativação Camada Interna 1	Neurônios Camada Interna 2	Função de Ativação Camada Interna 2	SSE	R ²
1	<i>trainlm</i>	10	<i>logsig</i>	-	-	0.0436	0.99992
	<i>trainbr</i>	10	<i>logsig</i>	-	-	0.0497	0.99993
	<i>trainoss</i>	10	<i>logsig</i>	-	-	0.3390	0.99939
	<i>traingdx</i>	10	<i>logsig</i>	-	-	2.0100	0.99636
	<i>traincgb</i>	10	<i>logsig</i>	-	-	0.1410	0.99974
	<i>trainlm</i>	10	<i>logsig</i>	10	<i>logsig</i>	0.0246	0.99996

- *trainlm* e *trainbr* tiveram performances superiores
- *traingdx* piores resultados
- Fixando o *trainlm* e variando número de camadas a melhora não foi significativa

Resultados e Discussões

Modelo	Algoritmo de Treinamento	Neurônios Camada Interna 1	Função de Ativação Camada Interna 1	Neurônios Camada Interna 2	Função de Ativação Camada Interna 2	SSE	R2
2	<i>trainlm</i>	10	<i>tansig</i>	-	-	0.0475	0.99992
	<i>traingdx</i>	10	<i>tansig</i>	-	-	3.9100	0.99302
	<i>traingdx</i>	10	<i>logsig</i>	-	-	21.3000	0.96135
	<i>trainlm</i>	30	<i>tansig</i>	-	-	0.0377	0.99993
	<i>trainlm</i>	5	<i>tansig</i>	5	<i>tansig</i>	0.0411	0.99993
	<i>trainlm</i>	10	<i>logsig</i>	10	<i>tansig</i>	0.0429	0.99993

- *traingdx* mostrou resultados inferiores com diferentes funções
 - Consolidando o padrão desse algoritmo para este caso
- *trainlm* foi avaliado com 10 e 30 neurônios, com os resultados não variando significativamente, com o mesmo ocorrendo com duas camadas

Resultados e Discussões

Modelo	Algoritmo de Treinamento	Neurônios Camada Interna 1	Função de Ativação Camada Interna 1	Neurônios Camada Interna 2	Função de Ativação Camada Interna 2	SSE	R2
3	<i>trainlm</i>	5	<i>tansig</i>	5	<i>tansig</i>	0.0072	0.99998
	<i>trainlm</i>	5	<i>logsig</i>	5	<i>logsig</i>	0.0271	0.99995
	<i>trainoss</i>	10	<i>tansig</i>	-	-	0.0540	0.99989
	<i>trainoss</i>	10	<i>logsig</i>	-	-	0.0810	0.99984
	<i>trainbr</i>	5	<i>logsig</i>	5	<i>logsig</i>	0.0165	0.99997
	<i>trainbr</i>	5	<i>tansig</i>	5	<i>tansig</i>	0.0169	0.99998


4	<i>trainbr</i>	5	<i>tansig</i>	5	<i>tansig</i>	0.0068	0.99999
	<i>trainbr</i>	5	<i>logsig</i>	-	-	0.0272	0.99995
	<i>trainbr</i>	10	<i>logsig</i>	-	-	0.0277	0.99996
	<i>trainoss</i>	10	<i>tansig</i>	-	-	1.9200	0.99664
	<i>trainoss</i>	10	<i>logsig</i>	-	-	2.2800	0.99634
	<i>trainbr</i>	3	<i>tansig</i>	3	<i>tansig</i>	0.0320	0.99995

- *trainbr* com mesmo número de neurônios mas diferentes funções obteve resultados praticamente iguais
- *trainlm* com mesmo número de neurônios mas diferentes funções obteve alteração significativa no SSE
- *trainoss* no Modelo 4 apresentou resultados significativamente piores que os outros algoritmos, porém no Modelo 3 o mesmo gerou bons resultados

Resultados e Discussões

Modelo	Algoritmo de Treinamento	Neurônios Camada Interna 1	Função de Ativação Camada Interna 1	Neurônios Camada Interna 2	Função de Ativação Camada Interna 2	SSE	R ²
1	trainlm	10	logsig	-	-	0.0436	0.99992
2	trainlm	10	tansig	-	-	0.0475	0.99992
3	trainlm	5	tansig	5	tansig	0.0072	0.99998
4	trainbr	5	tansig	5	tansig	0.0068	0.99999





Maior gasto computacional



Maior gasto computacional



Conclusão



Conclusão

- Método de realização simples
- Rápida obtenção
- Mais preciso
- Capacidade de modelar grandes dados
- Não necessitou de conhecimento prévio do processo, ou seja, garantia que não é enviesado por um conhecimento incerto
- Importante passo à frente na exploração do potencial brasileiro na obtenção de potássio via glauconita