

Trabalho de Conclusão de Curso

Aprendizagem de máquina aplicada em processos de conversão do metano

Alunas: Gabriela F. Pimenta da Silva & Mariana C. Monteiro de Almeida

Orientadora: Amanda Lemetite Teixeira Brandão

Coorientadora: Andréa Pereira Parente



Introdução

- *Expert Systems*: programas que imitavam a resolução de problemas de humanos em áreas específicas (FEIGENBAUM, 1992).
- Redes neurais: Forma de inteligência artificial cujo treino se dá de forma similar à conexões neurais do cérebro humano.
- *Deep Learning*: Tem como base redes neurais profundas e a aprendizagem de máquina estatística.




Figura 1 : Linha do tempo da evolução da inteligência artificial (as AUTORAS)

- Atual desafio da era “*Deep Learning*”: falta de padronização no armazenamento de *big data*.
 - Utilização da modelagem e simulação como ferramenta auxiliar à padronização de dados

Introdução

- Crescente preocupação ambiental: Gás natural como combustível aliado na transição.

PCS DE DIVERSOS COMBUSTÍVEIS




Gráfico 1 : PCS de combustíveis (SANTOS e SANTOS, 2005)

- Demanda universal crescente de hidrocarbonetos precursores de polímeros.
 - Alternativa para o processo petroquímico de obtenção do etileno.
- Aprendizagem de máquinas atrelados aos processos da indústria de óleo e gás como estratégia inteligente e viável de controle de processos.



Objetivo

- Desenvolvimento de modelos de aprendizagem de máquina na linguagem Python, buscando realizar a predição das variáveis de saídas de duas diferentes rotas de conversão do metano;
 - Estudos de caso:
 - ❑ Reforma a vapor do metano em um reator de membrana
 - ❑ Acoplamento oxidativo do metano em um reator de leito fixo para se obter C2*
- Emprego de modelo direto;
- Obtenção das respostas do modelo relacionadas à conversão do CH₄ (rendimento, conversão e seletividade).

* Etano e etileno.

Revisão Bibliográfica

ACOPLAMENTO OXIDATIVO DO METANO (OCM)

Processo no qual o CH_4 e o O_2 sob condições de alta temperatura na presença de um catalisador produz etano e etileno.

Segundo Stansch *et. al* (1997), os parâmetros ótimos estão entre as seguintes faixas:

- Temperatura (700 - 955 °C)
- Pressão (100 kPa a 130 kPa)
- Razão CH_4/O_2 (2 a 25)
- Tipo de catalisador ($\text{La}_2\text{O}_3/\text{CaO}$)




Figura 2 : Exemplificação de um reator PFR (as AUTORAS)

Revisão Bibliográfica

REFORMA A VAPOR DO METANO

Reação endotérmica. Se dá pela reação do metano com água em altas temperaturas:

- $\text{CH}_4 + \text{H}_2\text{O} \leftrightarrow \text{CO} + 3\text{H}_2$ Eq. (1)
- $\text{CH}_4 + 2 \text{H}_2\text{O} \leftrightarrow \text{CO}_2 + 4\text{H}_2$ Eq. (2)
- $\text{CO} + \text{H}_2\text{O} \leftrightarrow \text{CO}_2 + \text{H}_2$ Eq. (3)

De acordo com ROY, 1998 e FARRAUTO, 2016 para obtenção do gás de síntese tem-se:

- Temperatura: 700 - 1000 °C
- Pressão: 15 - 40 atm
- Rendimento H_2/CH_4 : 2,2 - 2,7




Figura 3 : Exemplificação de um reator de membrana (as AUTORAS)



Revisão Bibliográfica

APRENDIZAGEM DE MÁQUINA

O método de aprendizagem de máquina baseia-se na combinação de vários modelos de aprendizado, em que o resultado final é determinado pela agregação dos resultados fornecidos por cada um dos modelos individualmente.

- **SUPERVISIONADO:** o modelo é treinado usando um conjunto de dados rotulados, onde cada exemplo é acompanhado por uma etiqueta indicando a resposta correta.
- **NÃO-SUPERVISIONADO:** o modelo é treinado em um conjunto de dados não rotulados, e o objetivo é descobrir padrões ou estruturas ocultas nos dados, como clusters ou distribuições.
- **POR REFORÇO:** o modelo é treinado para interagir com um ambiente e aprender a tomar decisões que maximizem uma recompensa ao longo do tempo.

Revisão Bibliográfica

RANDOM FOREST (RF)

O *Random Forest* é um modelo composto por um conjunto “ n ” de árvores de decisão geradas aleatoriamente, que geram respostas únicas. O modelo RF calcula a média das previsões geradas por todas as árvores para fornecer um valor final.




Figura 4 : Esquema simplificado do algoritmo de RF (WANG,2019)

Revisão Bibliográfica

XGBOOST

XGBoost (Extreme Gradient Boosting) é um algoritmo de aprendizagem de máquina que usa um conjunto de árvores de decisão para fazer previsões. O *XGBoost* usa uma técnica de otimização chamada de gradiente estocástico descendente para ajustar os pesos dos modelos de árvore e, assim, melhorar a precisão das previsões.




Figura 5 : Esquema simplificado do algoritmo XGBoost (WANG, 2019)

Metodologia




Figura 6 : Fluxograma metodológico do processo (as AUTORAS)

Metodologia

Tabela 1: Variáveis do processo OCM (as AUTORAS)

Variáveis de Entrada (X)	Variáveis de Saída (Y)
Fração molar de alimentação de CH ₄	Conversão O ₂
Razão molar de alimentação CH ₄ /O ₂	Conversão CH ₄
Temperatura (K)	Seletividade C ₂
Pressão (kPa)	Rendimento C ₂
Vazão volumétrica STP	Rendimento C ₂ H ₆
	Rendimento CO ₂
	Rendimento CO

Tabela 2: Variáveis do processo COM (as AUTORAS)

Variáveis de Entrada (X)	Variáveis de Saída (Y)
FH ₂ O – Vazão molar inicial de hidrogênio (Kgmol/h)	XCH ₄ – Fração molar de metano
FCO ₂ O/CH ₄ O – razão da vazão molar inicial de dióxido de carbono por metano	XCO ₂ – Fração molar de dióxido de carbono
P ₀ – Pressão inicial (bar)	FH ₂ – Vazão molar de hidrogênio (Kgmol/h)
T ₀ – Temperatura Inicial (K)	FH ₂ w – Vazão molar de hidrogênio no permeado (Kgmol/h)
	FCH ₄ – Vazão molar de metano (Kgmol/h)
	FCO ₂ – Vazão molar de dióxido de carbono (Kgmol/h)
	P – Pressão final (bar)

Resultados

ACOPLAMENTO OXIDATIVO DO METANO

Foram feitas 7776 simulações ao final da geração de dados.

Tabela 3 : Descrição numérica do modelo Random Forest

	Nº de simulações	Nº total de dados
Treino	5.599	67188
Teste	778	9.336
Validação	1399	16.788




Figura 7 : Correlação de Spearman para o processo COM (as AUTORAS)

Resultados

ACOPLAMENTO OXIDATIVO DO METANO

Tabela 4 : Métricas de uma das simulações do processo OCM

	R ²	RMSE
Treino	0,8424	2,8474
Validação	0,7695	3,5697
Teste	0,7596	3,5067

Tabela 5 : Desvio padrão, variância e RMSE da simulação considerando a predição de todas as variáveis de saída

Métricas	Variáveis						
	XO2	XCH4	SC2	YC2	YC2H6	YCO2	YCO
Desvio padrão	2,654	0,5055	14,3558	0,3091	0,302	0,0677	0,1482
Variância	7,0435	0,2555	206,0889	0,0956	0,0912	0,0046	0,022
RMSE ^v	3,5697						
RMSE ^t	3,5067						

Resultados

ACOPLAMENTO OXIDATIVO DO METANO

Tabela 6: Métricas do modelo RF obtidas para XO2, XCH4 e YC2

	XO2		XCH4		YC2	
	R ²	RMSE	R ²	RMSE	R ²	RMSE
Treino	0,9999	0,0248	0,9999	0,0062	0,9999	0,0026
Validação	0,9993	0,0588	0,9996	0,0135	0,9994	0,0075
Teste	0,9994	0,0639	0,9992	0,0173	0,9997	0,0063

Tabela 7 : Desvio padrão, variância e RMSE para as variáveis de saída preditas usando o modelo RF

Métricas	Variáveis						
	XO2	XCH4	SC2	YC2	YC2H6	YCO2	YCO
Desvio padrão	2,3737	0,6178	13,4433	0,3197	0,3116	0,1066	0,2070
Variância	5,6345	0,3817	180,7223	0,1022	0,0971	0,0114	0,0428
RMSE^v	0,0588	0,0135	0,0363	0,0075	0,0069	0,0029	0,0059
RMSE^t	0,0639	0,0173	0,0354	0,0063	0,0068	0,0024	0,0065

Resultados

ACOPLAMENTO OXIDATIVO DO METANO

A maioria dos pontos se encontram densamente compactados em torno da reta central, indicando que o modelo está produzindo previsões precisas.




Figura 8 : Dados simulados *versus* dados originais. Onde: A) XO_2 , B) XCH_4 , C) SC_2 , D) YC_2 , E) YC_2H_6 , F) YCO_2 e G) YCO (as AUTORAS)

Resultados

REFORMA A VAPOR DO METANO

Foram feitas 33.895 simulações ao final da geração de dados.

Tabela 8: Descrição numérica do modelo XGBoost

	Nº de simulações	Nº total de dados
Treino	24.404	268.444
Teste	3.390	37.290
Validação	6.101	67.111




Figura 9 : Correlação de Spearman para o processo de Reforma a vapor (as AUTORAS)

Resultados

REFORMA A VAPOR DO METANO

Tabela 9: Valores do coeficiente de determinação, RMSE, variância e desvio padrão do modelo *XGBoost*

Métricas	Variáveis					
	XCH4	FH2W	XCO2	P	FCH4	FCO2
R^{2tr}	0,97513	0,97248	0,97500	0,54558	0,97679	0,98134
R^{2v}	0,97481	0,98076	0,97367	0,54114	0,97637	0,94098
R^{2t}	0,97412	0,98047	0,97447	0,54266	0,97619	0,98057
Desvio padrão	0,08215	1,95007	0,08250	1,65630	0,45208	0,48756
Variância	0,00675	3,80277	0,00681	2,74333	0,20438	0,23771
RMSE ^{tr}	0,00904	0,24120	0,00906	0,92051	0,04899	0,04875
RMSE ^v	0,00912	0,19869	0,00912	0,90881	0,04931	0,08799
RMSE ^t	0,00924	0,19834	0,00914	0,90112	0,04949	0,04978

Resultados

REFORMA A VAPOR DO METANO




Figura 10 : Dados preditos versus dados originais. Onde: A) XCH4, B) FH2w
C) XCO2, D) P, E) FCH4, F) FCO2 (as AUTORAS)

Tabela 10: Melhores valores para os hiperparâmetros do modelo XGBoost por variável

	N_estim ators	Max_ depth	Min_child _weight	Learning_rate
XCH4	342	3	1	0.09457063
FH2w	266	4	10	0.06187435
XCO2	375	3	1	0.09673835
P	194	2	10	0.04876721
FCH4	355	4	1	0.05519967
FCO2	351	6	9	0.05427770



Conclusão

Random Forest

- O *Random Forest* provou ser uma ferramenta poderosa e eficaz capaz de ser utilizada em um dos processos mais complexos.
- A previsão de variáveis individualmente foi uma grande melhoria no desempenho do modelo.
- A utilização da estratégia de um *output* único é vantajosa, uma vez que ML são modelos não paramétricos.

XGBoost

- O *XGBoost* demonstrou alta acurácia, sendo assim um modelo confiável a ser replicado.
- Como foi adotado o modelo MISO desde o primeiro momento, o alto desempenho do modelo foi favorecido.
- Com exceção da pressão que obteve um R^2 geral de 0,54, as demais variáveis obtiveram um R^2 acima de 0,97 para os conjuntos de teste, treino e validação.



Conclusão

No geral:

- A aplicação e exploração dos dois algoritmos de aprendizagem de máquinas a dois processos de grande importância na indústria petroquímica foi bem sucedida.
- Os modelos de aprendizagem de máquinas utilizados se mostraram robustos suficientes e depois de treinados podem ser usados como ferramentas de monitoramento e controle online em instalações industriais.



Trabalhos Futuros

- Explorar a relação da Pressão com o processo com o objetivo de melhorar suas métricas de predição.
- Aplicar melhorias no modelo OCM, com por exemplo, a incorporação de dados tridimensionais do reator em vez de um modelo 1D. Usando dados 3D, o modelo seria capaz de capturar informações mais detalhadas sobre o reator e, portanto, fornecer previsões mais precisas.

Agradecimentos



Família LaMAC PUC-Rio!



PUC
RIO



LaMAC



DEPARTAMENTO DE ENGENHARIA
QUÍMICA E DE MATERIAIS





Referências

FARRAUTO, R. J. Introduction to catalysis and industrial catalytic processes. John Wiley & Sons, 2016.

FEIGENBAUM, E. A. "A personal view of expert Systems: Looking back and looking ahead", Department of computer Science – Stanford University, 1992.

ROY, S. Economics and simulation of fluidized bed membrane reforming. Int. J. Hydrogen Energy, v. 23, n.9, p. 745-752,1998

STANSCH, Z.; MLECZKO M, L.; BAERNS. Comprehensive Kinetics of Oxidative Coupling of Methane over the La₂O₃/CaO Catalyst. Industrial and Engineering Chemistry Research, v. 36, n. 7, p. 2568–2579, 1997.

SANTOS, F. M. S. M. D.; SANTOS, F. A. C. M. D. O Combustível "Hidrogênio". Millennium on. Line, v. 31, p. 252-270, 2005. Disponível em: <www.ipv.pt/millennium>.

Wang,Y.; Pan,Z.; Zheng, J.; Qian,L.; Li, M. A hybrid ensemble method for pulsar candidate classification.Astrophys Space Sci (2019) 364:139.



Obrigada !