



Projeto de Conclusão de Curso

Aprendizagem de máquina aplicada em processos de conversão do metano

Gabriela F. Pimenta da Silva - 1621561
Mariana C. Monteiro de Almeida - 1620743

Orientadora:
Amanda Lemette Teixeira Brandão

Coorientadora:
Andréa Pereira Parente

Rio de Janeiro, Março de 2023



Aprendizagem de Máquina Aplicada a Processos de Conversão do Metano

Trabalho de Conclusão de Curso

Projeto de graduação em Engenharia Química apresentado ao Departamento de Engenharia Química e de Materiais da PUC-Rio, como parte dos requisitos para obtenção do título de Engenheira Química.

Orientadora: Amanda Lemette Teixeira Brandão
Coorientadora: Andréa Pereira Parente

Rio de Janeiro
Março de 2023

Agradecimento

Agradeço primeiramente aos meus pais por todo amor, suporte e parceria. À memória de meu pai, Marcos Thomé, que me proporcionou a melhor educação e foi, para além de exemplo de amor, meu melhor amigo desde o início da minha vida até seu último dia em terra. À minha mãe, Vânia Cristina, por seguir sendo uma mãe singular, companheira e a melhor amiga que eu poderia ter.

À minha família que foi o pilar ao longo de toda minha caminhada educacional até aqui.

Ao NEAM e ao ITUC, destacando Dra. Marina Lemette, Prof. MSc. Pedro Paulo e Prof. Dr. Sérgio Braga, por terem acreditado e impulsionado minha capacitação profissional.

Aos meus amigos, Juliana Andrade, Juliana Carmo, Kethlyn Goutsis e Yuri João que estão comigo desde a infância e seguiram me dando força e parceria ao longo desses anos.

Aos meus amigos, Anna Karolina, Larissa Azevedo, Leandro Verçosa, Maria Luiza, Taíssa Guimarães e Victor Hugo, que trago comigo desde o ensino médio e ao longo de minha jornada na universidade pude compartilhar momentos de lazer que tornaram essa caminhada mais leve.

Aos meus amigos, Ariele Santos, Gabriela Pimenta, João Pedro, Lorraine Oliveira, Rebecca Downey, Roberta Lamosa. cujos laços de amizade foram construídos através das vivências na PUC e pude compartilhar choros e alegrias ao longo dos anos de graduação.

As minhas amigas Maiara Santana e Natália Temístocles, por toda troca, sintonia ao longo de minha caminhada universitária.

A Prof. Dra. Amanda Lemette Brandão e a Dra. Andréa Parente, por terem aceitado e orientado a presente tese e serem referências de Engenheiras químicas.

Ao PRH-ANP 23.1 e ao LaMAC-PUC-Rio, por nos darem assistência durante a nossa pesquisa.

Como agradecimento geral aqueles citados e aos não mencionados, mas que também esbarrei ao longo dessa caminhada, obrigada pela convivência e por terem contribuído à sua forma para o meu crescimento pessoal e profissional.

Mariana

Agradecimento

Agradecemos primeiramente aos meus pais, por todo suporte, amor e ajuda, que muito contribuíram com a nossa formação acadêmica durante os nossos anos de estudo. Principalmente ao tio Marcos, que deu muito suporte ao longo da nossa jornada, mas infelizmente, não pôde ver a sua filha se formando.

Agradecemos também a todas as pessoas com quem convivemos ao longo desses anos de curso, que nos proporcionaram experiências que permitiram o nosso crescimento não só como pessoa, mas também como profissionais e acima de tudo, nos incentivaram a ir atrás dos nossos sonhos.

A professora Dra. Amanda Lemette Brandão e a Dra. Andréa Parente, nossa orientadora e coorientadora, agradecemos por todos os conselhos, ajuda e paciência com a qual guiaram-nos durante a conclusão do nosso curso.

Ao PRH-ANP 23.1 e ao LaMAC-PUC-Rio, por nos darem suporte durante a nossa pesquisa.

Gabriela

Resumo

O presente trabalho traz como estudo de caso a aplicação de algoritmos de aprendizagem de máquinas (do inglês, *Machine Learning* - ML) em dois importantes processos da indústria de óleo e gás: a reforma a vapor do metano e o acoplamento oxidativo do metano (do inglês, *Oxidative Coupling of Methane* - OCM). Em ambos os estudos de caso realizados neste trabalho, foram utilizados modelos determinísticos/fenomenológicos para gerar as base de dados usadas para treinar os modelos empregando os algoritmos de *Random Forest* (RF) e *XGBoost*. Para o estudo do processo OCM, o modelo *Random Forest* recebe como variáveis de entrada a fração molar de alimentação CH_4 , relação molar de alimentação CH_4/O_2 , temperatura, pressão e fluxo de volume de gás STP para prever o rendimento, conversão e seletividades da reação. Para a reforma a vapor, o modelo *XGBoost* recebe como variáveis de entrada a razão da vazão molar inicial CO_2 por CH_4 , vazão molar inicial de hidrogênio H_2 , pressão inicial e temperatura inicial. Ao final do estudo, tanto o modelo RF de regressão para o processo OCM quanto o modelo *XGBoost* apresentaram uma boa resposta para a predição das saídas individuais de alguns parâmetros, mostrando que o emprego de inteligência artificial nesses processos funciona como uma importante estratégia para obter informações relevantes que poderão ser usadas para o controle e monitoramento do processo.

Palavras-chave: Machine Learning, *Random Forest*, *XGBoost*, Modelagem, Otimização.

SUMÁRIO

1. INTRODUÇÃO.....	1
2. OBJETIVOS	3
3. REVISÃO BIBLIOGRÁFICA.....	3
3.1 Rotas de conversão do metano.....	3
3.2 Acoplamento oxidativo do metano	4
3.3 Reforma a vapor do metano	5
3.4 Reator de leito fixo	6
3.5 Reator com membrana.....	7
3.6 Aprendizagem de máquina	7
3.6.1 Random Forest.....	8
3.6.2 XGBoost	9
4. METODOLOGIA.....	11
4.1 Desenvolvimento de modelos fenomenológicos	11
4.1.1 Acoplamento oxidativo do metano	11
4.1.2 Reforma a vapor do metano	14
4.2 Geração dos dados	16
4.2.1 Acoplamento oxidativo do metano (OCM)	16
4.2.2 Reforma a vapor do metano	17
4.3 Desenvolvimento de Modelos de aprendizagem de máquinas	18
4.3.1 Pré-processamento dos dados	19
4.3.2 Treinamento e validação do modelo.....	20
4.3.3 Regressão via Random Forest.....	20
4.3.4 Regressão via XGBoost.....	22
5. RESULTADOS	23
5.1 Random Forest	23
5.2 XGBoost.....	29
6. CONCLUSÃO	34
7. TRABALHOS FUTUROS	35
8. REFERÊNCIAS	36

LISTA DE FIGURAS

Figura 1:Esquema simplificado do algoritmo de Random Forest (LEE,2017)	8
Figura 2 : Fluxograma do processo.....	11
Figura 3: Geração da base de dados	17
Figura 4: Dataset gerado através do modelo fenomenológico para o processo OCM	23
Figura 5: Correlação de Spearman para o processo OCM (as AUTORAS)	24
Figura 6: Dados simulados versus dados originais. Onde: A) XO ₂ , B) XCH ₄ , C) SC ₂ , D) YC ₂ , E) YC ₂ H ₆ , F) YCO ₂ e G) YCO	28
Figura 7: Dataset gerado através do modelo fenomenológico para o processo de reforma a vapor	29
Figura 8: Correlação de Spearman para o processo de reforma a vapor do metano (as AUTORAS).....	30
Figura 9: Dados preditos versus dados originais. Onde: A) XCH ₄ , B) FH ₂ w C) XCO ₂ , D) P, E) FCH ₄ , F) FCO ₂	33

LISTA DE TABELAS

Tabela 1: Parâmetros cinéticos propostos pelo modelo de STANSCH, MLECZKO e BAERNS (1997)	13
Tabela 2: Intervalo da variável no gerador de dados para o processo OCM	16
Tabela 3: Intervalo da variável no gerador de dados para o processo de reforma a vapor	17
Tabela 4: Variáveis de entrada e saída do processo de reforma a vapor	18
Tabela 5 :Variáveis de entrada e saída usadas no modelo RF para o processo OCM.	20
Tabela 6: Dados de estudo no Optuna para o processo OCM.....	21
Tabela 7: Dados do Optuna para o processo de reforma a vapor	22
Tabela 8: Descrição numérica do modelo Random Forest	23
Tabela 9: Métricas de uma das simulações do processo OCM	25
Tabela 10: Desvio padrão, variância e RMSE da simulação considerando a predição de todas as variáveis de saída.....	25
Tabela 11: Métricas do modelo RF obtidas para XO ₂ , XCH ₄ e YC ₂	27
Tabela 12: Desvio padrão, variância e RMSE para as variáveis de saída previstas usando o modelo RF.....	27
Tabela 13: Descrição numérica do modelo XGBoost.....	30
Tabela 14: Melhores valores para os hiperparâmetros do modelo XGBoost por variável	31
Tabela 15: Valores do coeficiente de determinação do modelo	32
Tabela 16: Valores de RMSE, variância e desvio padrão do modelo XGBoost	32

LISTA DE ABREVIATURAS, SIGLAS E SÍMBOLOS

OCM - do inglês, *Oxidative Coupling of Methane* (Acoplamento oxidativo do metano)

RF - Random Forest

RMSE – Root Mean Square Error (Raiz do erro quadrático médio)

ML - *Machine learning*

C2 - hidrocarbonetos C₂H₆ e C₂H₄

v : Velocidade (m.s⁻¹)

ε: Porosidade do leito catalítico

ρ_b : Densidade do catalisador no reator (g.m³)

Ṃ: Vazão volumétrica

A: Área do PFR

k_{0,j} - Fator pré-exponencial

E_{a,j} - Energia de ativação na reação j, J/mol

K_j - Constante de adsorção, Pa⁻¹

ΔH_{ad,CO₂} - Entalpia de adsorção para o CO₂, J/mol

ΔH_{ad,O₂} - Entalpia de adsorção para o O₂, J/mol

m_j - Ordem de reação

n_j - Ordem de reação

p_j - Pressão parcial do componente j

F_j - Vazão do componente j

F⁰_{CH₄} - Vazão de metano na entrada do reator

P_P - Pressão parcial do hidrogênio no lado de permeação

R_m - Raio do tubo da membrana

W - Massa do catalisador

L - Comprimento total do tubo de membrana

β - Permeância da membrana

1. INTRODUÇÃO

A inteligência artificial teve seu desenvolvimento engatilhado na década de 60, em uma era denominada *Expert Systems*, estes eram programas que imitavam a resolução de problemas de humanos em áreas específicas, nessa era surgiram as suas primeiras aplicações à engenharia, mas sem grandes avanços por demandar muito tempo, esforço e dinheiro (FEIGENBAUM, 1992). Só na década de 90, com o advento da era das redes neurais, houve uma expansão de aplicação aos problemas da engenharia uma vez que havia melhorias contínuas das aplicações, mas ainda havia desafios a serem resolvidos como, por exemplo, a necessidade de uma grande capacidade de armazenamento de informações. Atualmente, vive-se a era do *Deep Learning*, que tem como braços as redes neurais profundas e a aprendizagem de máquinas estatística, tais braços contam com aplicações em vários ramos da indústria em operações de processos e diagnóstico de falhas.

Um dos desafios atuais da implementação de inteligência artificial é a falta de padronização no armazenamento de *big data*, isto é, uma grande base de dados de informações que favoreça o programa a reconhecer os padrões do processo através da correlação implícita entre as variáveis do mesmo para então ele ser capaz de prever com o máximo de exatidão as variáveis de saída de interesse. A engenharia química é uma área regida por leis da física, química e matemática, tal fato permite o uso da modelagem e simulação como auxiliar para a geração desse grande banco de dados com as variáveis chave de análise.

Seguindo a linha de desafios atuais, mas em outra área, tem-se a transição energética. A crescente preocupação com a situação ambiental tem levado a indústria em diversos departamentos a optar por políticas sustentáveis. Em um dos campos mais relevantes da indústria, que é o setor de óleo e gás, essa transição tem como principal aliado o gás natural, uma vez que sua composição é majoritariamente metano, possibilitando assim a aplicação a diversos processos com finalidades distintas, mas com uma motivação em comum: a diminuição da emissão de hidrocarbonetos pesados à atmosfera.

Parte dos hidrocarbonetos lançados à atmosfera estão atrelados ao uso de combustíveis fósseis, por isso, o hidrogênio é uma excelente solução ao problema

uma vez que quando comparado a outros combustíveis, este possui uma maior capacidade calorífica. O hidrogênio enquanto substância é escasso e torna-se necessária a execução de processos para sua obtenção, o processo mais usado pela indústria é o de reforma a vapor (SANTOS, 2019; ANDREWS, 2020), que tem como produto o gás de síntese que é composto por monóxido de carbono (CO) e hidrogênio (H₂). Quando o processo de reforma a vapor ocorre em um reformador de membrana o hidrogênio é separado sem a necessidade de uma unidade secundária de operação, aumentando a eficiência do processo.

Outro hidrocarboneto bastante utilizado é o etileno, tal polímero tem diversas aplicações como PET, PVC e afins, o que implica em uma alta demanda mundial que segue em constante crescimento. Como redução de danos buscam-se formas alternativas para o processo petroquímico de obtenção desse polímero. A rota mais promissora é o acoplamento oxidativo do metano que, em contrapartida, ainda é bastante desafiadora uma vez que possui baixa seletividade para produtos C₂ além de ser altamente exotérmica (ALMEIDA e SANTOS, 2022).

Na literatura, há diversos registros de aprendizagem de máquinas atrelados aos processos da indústria de óleo e gás, TAKAHASHI *et al.* (2018) e NISHIMURA *et al.* (2020) utilizaram para descobrir combinações catalíticas para as reações do processo de acoplamento oxidativo do metano (do inglês, *Oxidative Coupling of Methane* - OCM), assim como ADENIYI, IGHALO e MARQUES (2021) usando Redes neurais artificiais fizeram a modelagem da composição do gás de síntese advindo do processo de reforma a vapor de bio-óleo de biomassa.

O presente estudo de caso se inicia com a simulação de dois grandes processos da indústria que tem o metano como componente chave e a cada um dos processos foi aplicado um modelo de aprendizagem de máquinas. A finalidade deste é guiar para um caminho onde é possível implementar uma estratégia inteligente e viável de monitoramento de processos usando algoritmos de aprendizado de máquinas como forma de supervisão de equipamentos através de manutenção preditiva (ALMEIDA, de ANDRADE e de SOUZA, 2020).

2. OBJETIVOS

O presente trabalho tem como proposta o desenvolvimento de modelos de aprendizagem de máquina na linguagem Python, buscando realizar a predição das variáveis de saídas de duas diferentes rotas de conversão do metano. Para isso, serão realizados dois estudos de caso: reforma a vapor do metano em um reator de membrana e o acoplamento oxidativo do metano em um reator de leito fixo para se obter C2 (etano e etileno). As simulações em ambos os estudos de caso serão realizadas por um modelo direto, onde serão empregadas as condições iniciais de processo (pressão, temperatura, vazão etc.) a fim de se obter as respostas do modelo relacionadas à conversão do metano (rendimento, conversão e seletividade dos produtos gerados).

3. REVISÃO BIBLIOGRÁFICA

3.1 Rotas de conversão do metano

A elevada quantidade de matéria-prima disponível faz com que cresça a quantidade de estudos tecnológicos relacionados às rotas de conversão do metano para produção de combustíveis e produtos químicos, as principais rotas conhecidas são a direta e a indireta (LUNSFORD, 2000).

A rota do tipo direta é um método de etapa única que não demanda etapas intermediárias. Os métodos mais conhecidos deste tipo de rota são:

- Acoplamento oxidativo do metano (no inglês, *Oxidative Coupling of Methane* - OCM) e gera como produtos os hidrocarbonetos C2 (etano e etileno), que possuem grande importância na indústria química devido às suas diversas aplicações.
- Conversão em aromático sem oxidante, onde, a partir de uma conversão catalítica do substrato, obtém-se como produto da conversão: benzeno, tolueno e naftaleno.
- Oxidação seletiva do metano para obter metanol e formaldeído

A conversão indireta do metano, diferentemente da rota anterior, é composta por uma etapa intermediária na qual o metano é convertido em gás de síntese e posteriormente, é possível converter o produto desta etapa em produtos com valor agregado, como hidrocarbonetos e álcoois de cadeias maiores, empregando o

processo de Fischer-Tropsch (WANG, CONG e YANG, 2005). As rotas tecnológicas comumente aplicadas são:

- Reforma a vapor do metano que está intimamente ligada à indústria do petróleo por utilizar gás natural, é uma das principais rotas para obter hidrogênio, se tornando assim um importante processo no momento de transição energética vivenciado atualmente.
- Reforma seca, ou reforma com CO_2 , que tem um grande apelo ambiental pelo fato do gás de síntese, produto dessa reação, se originar da junção de outros dois gases (CH_4 e CO_2) relacionados ao efeito estufa. (SANTOS, 2019)
- Oxidação parcial do metano

A maioria dessas reações são de natureza endotérmica durante a produção do gás de síntese. Assim, é necessário que seja inserido calor ao sistema, geralmente realizado por trocadores de calor. Ademais, também se faz necessário um pré-tratamento do metano para remoção de contaminantes, como ácidos e nitrogênio.

3.2 Acoplamento oxidativo do metano

O processo de acoplamento oxidativo do metano (OCM) é um método complexo e tem grande potencial. Entretanto, ainda há algumas dificuldades relacionadas a este tipo de rota pois, ele possui uma baixa seletividade para o etano e etileno, baixo rendimento e produz como subprodutos monóxido e dióxido de carbono (GASPAR e DIEGUEZ, 2000).

O acoplamento oxidativo do metano é um processo no qual o CH_4 e o O_2 sob condições de alta temperatura na presença de um catalisador produz etano e etileno. Por essa rota de conversão, o metano alimentado no reator de leito fixo tem os seus radicais metila ativados e acoplados na presença de um agente oxidante, nesse caso, o oxigênio. Esse processo ocorre a temperaturas entre 750 – 850 °C, os produtos finais dessa rota são os hidrocarbonetos C_2 (SPALLINA, 2017). Entretanto, a formação do radical metila só é favorecida em temperaturas acima de 700 °C, o que acaba se tornando um empecilho de forma geral. Quando se trabalha com temperaturas acima de 700 °C, ocorre a desativação do catalisador, dependendo de qual catalisador está sendo empregado no processo (MUNIZ, 2007).










O tipo de catalisador utilizado no processo também já foi tema de outros estudos, a fim de se determinar as melhores combinações para que houvesse uma maior seletividade em relação aos hidrocarbonetos C_2 , como por exemplo a

combinação Mn/Na₂WO₄/SiO₂ (TAKAHASHI et al., 2018; EHSANI, BATENI e PARCHIKOLAEI, 2013). No entanto, até o presente momento, a combinação de catalisador com maior seletividade e menor índice de desativação foi La₂O₃/CaO (STANSCH, MLECZKO e BAERNS, 1997).

De acordo com a comunidade científica, o modelo cinético mais coerente e aceito é o modelo proposto por STANSCH, MLECZKO e BAERNS, 1997. Logo, o presente estudo foi realizado embasando-se nos parâmetros cinéticos propostos pelos autores. Aos quais temos que as condições de processo são estabelecidas entre os seguintes limites:

- Temperatura – 700 °C a 955 °C;
- Pressão - 100 kPa a 130 kPa;
- Razão CH₄/O₂ - 2 a 25.

O processo de acoplamento oxidativo do metano é descrito por 10 equações paralelas, onde devem ser consideradas reações na fase gasosa, efeito de inibição causado pelo oxigênio e o dióxido de carbono. As Equações 3.1 - 3.10 a seguir descrevem o processo OCM e seu funcionamento.



3.3 Reforma a vapor do metano

A reforma a vapor do metano se dá pela reação do metano com a água em altas temperaturas tendo como produto o monóxido de carbono e o hidrogênio conforme mostra a Equação 3.11. Nesta reação endotérmica há o excesso do vapor

de água, esse excesso faz com o que haja a formação de dióxido de carbono e hidrogênio conforme mostra a Equação 3.12, sendo esta reação a mais desejada uma vez que o monóxido de carbono é um gás tóxico e de difícil separação, essa conversão de monóxido de carbono em dióxido de carbono também é realizada através de um catalisador, dando origem a Equação 3.13 também conhecida como *Water Gas Shift*.



O principal produto gerado por esse processo de conversão é o hidrogênio (H_2). Segundo a literatura, o rendimento do H_2 produzido está em torno de 2,2 a 2,7 mols de hidrogênio por mol de CH_4 alimentado (ROY, 1998). Inicialmente, o gás natural usado como substrato é submetido a uma dessulfurização a fim de se remover o enxofre. Por se tratar de um processo catalítico, se faz necessário a remoção do contaminante para evitar que ocorra o envenenamento do catalisador. Desta forma, todos sítios catalíticos estarão disponíveis durante o processo de reforma.

Após a dessulfurização, o gás e uma corrente de vapor de água são encaminhados para a segunda etapa, onde ocorre a reação endotérmica para gerar o gás de síntese. Para que não haja a formação de coque no catalisador, aplica-se um excesso de vapor com uma razão variando entre 2 e 6 em relação à razão H_2O/CH_4 na corrente de alimentação. A obtenção do gás de síntese ocorre em altas temperaturas, variando a temperatura entre 700 – 1000 °C e pressão entre 15 - 40 atm (FARRAUTO, 2016). Como essa rota tecnológica avançada é bastante empregada, a conversão do método está entre 90 e 95 %. Em relação ao hidrogênio obtido do processo, este apresenta um grau de pureza elevado, em torno de 99 % (BHARADWAJ e SCHMIDT, 1995; LEE, SPEIGHT e LOYALKA, 2007).

3.4 Reator de leito fixo

O reator de leito fixo (PFR) é um vaso ou cilindro, onde são distribuídos sólidos particulados (também conhecidos como catalisadores) que estão dispostos de modo compacto e em estado estacionário, ou seja, o catalisador está fixo. O sentido de escoamento nesses reatores pode se dar no sentido de contracorrente (ascendente)

ou de forma paralela (descendente). Nesta primeira configuração, o escoamento da alimentação e do agente de gaseificação se dão de forma contrária, enquanto que na configuração paralela, os fluidos possuem o mesmo sentido de escoamento (WARNECKE, 2000).

Para realizar a reação dentro do PFR, o fluido alimentado no PFR escoar através das vacâncias promovidas pela disposição do catalisador empregado. Este tipo de esquema faz com que haja uma maior estabilidade, impedindo que ocorra a fluidização dentro do reator (BASU, 2013).

Considerando que o modelo unidimensional seja ideal, o gradiente de temperatura e concentração descrito pelo modelo ocorre somente no sentido axial do reator (FROMENT, BISCHOFF e DE WILDE, 1990).

3.5 Reator com membrana

Em geral, um reator de membrana tem como configuração a base tubular similar à do reator PFR mas com o acréscimo de ter um segundo tubo, esse tubo interno tem suas paredes envoltas pela membrana e é ele o meio reacional. O componente desejado deve atravessar essa membrana para o tubo externo, a parte entre o tubo externo e o interno é onde fica o permeado o qual o componente de interesse é arrastado por um gás inerte para sua separação.

A membrana do reator pode ter ou não uma função catalisadora, quando essa membrana atua como catalisador chama-se de reator de membrana catalítico (RMC), quando a membrana não tem essa função tem-se o reator catalítico de membrana inerte (RCMI).

Quando há um limite de conversão por causa do equilíbrio da reação, é possível contornar esse limite e aumentá-lo através do distúrbio da concentração de reagente ou produto.

3.6 Aprendizagem de máquina

Os algoritmos de aprendizagem de máquina usados neste trabalho baseiam-se no método de aprendizagem (do inglês, *Machine Learning*) em conjunto, sendo bastante eficazes e poderosos para lidar com problemas de classificação e regressão. O método de aprendizagem em conjunto consiste na combinação de múltiplos modelos de aprendizagem, em que o valor final será determinado a partir dos resultados fornecidos por cada um dos modelos individualmente (CUTLER, 2012). As

simulações de aprendizagem de máquinas em linguagem Python têm sido amplamente implementadas em diferentes áreas da Engenharia Química para previsão de variáveis de saída sob condições específicas de processo, o que acaba por facilitar e reduzir os custos em torno do estudo de otimização realizado.

3.6.1 Random Forest

Random Forest (RF) é um exemplo de modelo de conjunto ML; O RF é composto por n números de árvores de decisão geradas aleatoriamente, cada árvore em crescimento resulta num único valor que, no final, fornece um valor médio calculado pelo modelo sobre os n números de árvores de decisão estabelecidos durante a implementação do modelo (ARCE-MEDINA, 2009). Uma representação simplificada do Random Forest é feita na Figura 1.




Figura 1: Esquema simplificado do algoritmo de Random Forest (LEE,2017)

As variáveis independentes dentro do algoritmo são descritas como sendo um vetor aleatório de p componentes $X = (X_1, \dots, X_p)^T$, a variável independente, que é o valor predito pelo modelo, é expressa por Y e a distribuição desses vetores é descrita como sendo $P_{XY}(X, Y)$. O intuito do algoritmo é obter uma função objetivo $f(X)$ que seja capaz de prever o valor de Y ; para que isso aconteça, o algoritmo obtém o valor predito individualmente por cada árvore de decisão, desde que esse valor possua o menor erro possível. O erro do valor obtido pelo modelo é descrito pela Equação 3.14 (ARCE-MEDINA, 2009; LEE, 2017).

$$E_{XY}(L(Y, f(X)))$$

$$\text{Equação (3.14)}$$

Onde, $L(Y, f(X))$ é a medida da distância entre a função $f(X)$ e Y . A medida de perda realizada pelo modelo é feita a partir do erro quadrado médio (MSE), quanto menor o MSE, menor é o erro entre o valor predito e o observado. Assim, reescrevendo a equação utilizada para medir a distância entre os pontos, obtém-se a Equação 3.15 para um problema envolvendo regressão (ARCE-MEDINA, 2009).

$$L(Y, f(X)) = (Y - f(X))^2 \quad \text{Equação (3.15)}$$

De forma geral, a função final para retornar o valor vai ser a Equação 3.16.

$$f(X) = E(Y|X = x) \quad \text{Equação (3.16)}$$

A partir do conjunto de dados obtido de cada árvore de decisão, a resposta numérica apresentada pela RF é descrita pela Equação 3.17.

$$f(x) = \frac{1}{J} \sum_{j=1}^J h_j(x) \quad \text{Equação (3.17)}$$

Onde, a equação $f(x)$ é a média das aprendizagens de cada um dos modelos individuais gerados pelas árvores.

3.6.2 XGBoost

O *XGBoost* é um modelo baseado em árvores de decisão, onde a função objetivo $f(x)$ é composta da soma de duas partes. A primeira parte está atrelada à perda do treino, isto é, ela mede quão bem o modelo se ajusta aos dados treinados, isto é, dados que foram usados para aprendizagem do modelo. A segunda parte é a regularização, parâmetro que mede a complexidade das árvores. A função de perda usada pelo *XGBoost* é a perda quadrada, Equação 3.19, dada pelo quadrado da diferença entre o valor predito e o valor real (CHEN e GUESTRIN, 2016). A otimização de perda do treino encoraja a modelos preditivos, enquanto a otimização da regularização encoraja a um modelo generalizado mais simples.

$$f(x) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k) \quad \text{Equação (3.18)}$$

$$L(\theta) = \sum_i (\hat{y}_i - y_i)^2 \quad \text{Equação (3.19)}$$

Para analisar a complexidade de uma árvore, tem-se a função $\Omega(f_t)$, colocada na Equação 3.20, que soma o número de folhas e a normalização euclidiana do peso da folha, sendo γ e λ os valores de hiperparâmetros.

$$\Omega(f_t) = \gamma T + \lambda \sum_{j=1}^T w_j^2 \quad \text{Equação (3.20)}$$

No caso do XGBoost, a função de perda de treinamento é um termo aditivo chamado de boosting, nesta o valor final predito ($\hat{y}_i^{(t)}$) corresponde a soma do valor predito anterior e do novo modelo.

$$\hat{y}_i^{(t)} = \hat{y}_i^{(t-1)} + f_t(x_i) \quad \text{Equação (3.21)}$$

Para decompor a função de perda em função de adição, é usada a aproximação de Taylor, tal aproximação é usada para funções diferenciais bem definidas. Após aplicar Taylor, é chegado à sua forma quadrática (CHEN e GUESTRIN, 2016) que, somando ao termo de regularização, obtém-se a função objetivo como sendo:

$$f(x) = \sum_{j=1}^T \left[\left(\sum_{i \in I} \partial_{\hat{y}_i^{(t-1)}} l(y_i, \hat{y}_i^{(t-1)}) \right) w_i + \frac{1}{2} \left(\sum_{i \in H} \partial_{\hat{y}_i^{(t-1)}}^2 l(y_i, \hat{y}_i^{(t-1)}) + \lambda \right) w_j^2 \right] + \gamma T \quad \text{Equação (3.22)}$$

Partindo da Equação 3.22, a função objetivo é uma soma de T funções quadráticas e para cada função quadrática é possível derivar um peso ideal, Equação 3.23, e substituindo esse peso na função objetivo, se chega à função objetivo mínima.

$$w_j^* = - \frac{\left(\sum_{i \in I} \partial_{\hat{y}_i^{(t-1)}} l(y_i, \hat{y}_i^{(t-1)}) \right)}{\left(\sum_{i \in H} \partial_{\hat{y}_i^{(t-1)}}^2 l(y_i, \hat{y}_i^{(t-1)}) \right) + \lambda} \quad \text{Equação (3.23)}$$

A estrutura de aprendizagem é exaustiva, sendo assim, ela aumenta conforme a profundidade dos nós aumenta. Para cada nó há uma função objetivo antes da divisão do nó e uma depois com a quantidade de nós que resta na árvore. A decisão de um nó é dada pela função de ganho, que é similar ao cálculo de ganho usando a entropia. O ganho é dado pela soma dos nós da esquerda e dos nós da direita, seguida da subtração do hiperparâmetro vezes o número do nó. O algoritmo tem como gatilho para parar as divisões se a melhor divisão tiver um ganho negativo.

4. METODOLOGIA

A metodologia de ambos os processos pode ser dividida em duas grande etapas, a primeira consiste na geração do dataset, seguido da mineração dos dados, onde é feita a limpeza dos mesmo, garantindo que não haja *outliers* e produzindo análises estatísticas do conjunto de dados, o último passo dessa etapa consiste na divisão dos dados em dados de treino, teste e validação.

A segunda etapa se dá pela seleção do algoritmo e definição dos hiperparâmetros que necessitam serem estimados pois alguns não interferem na performance do modelo, após isso é usado otimização Bayesiana sobre os hiperparâmetros selecionados e então métricas de regressão são calculadas com o objetivo de validar o modelo regressor. Na Figura 2 é possível visualizar o fluxograma definido para construção do processo.




Figura 2: Fluxograma do processo

4.1 Desenvolvimento de modelos fenomenológicos

4.1.1 Acoplamento oxidativo do metano

Equacionamento do Reator

Para o desenvolvimento desta etapa do estudo, com o intuito de realizar o equacionamento das reações heterogêneas envolvidas no processo, considerou-se que o acoplamento oxidativo do metano simulado foi realizado em um reator de leito fixo (PFR) unidimensional (1D). O balanço de massa é dado pela equação 4.1.

$$\frac{\partial C_i}{\partial t} = v \frac{\partial C_i}{\partial z} + \rho_b r_i \rightarrow \left[\frac{\text{mol}}{\text{m}^3 \text{s}} \right] \quad \text{Equação (4.1)}$$

Considerando que o balanço de massa apresentado na equação 4.1 ocorre em regime permanente, a mesma pode ser reescrita, obtendo-se a equação 4.2.

$$v \frac{\partial C_i}{\partial z} = \rho_b r_i \rightarrow \left[\frac{\text{mol}}{\text{m}^3 \text{s}} \right] \quad \text{Equação (4.2)}$$

Para que o equacionamento seja capaz de representar efetivamente as reações envolvidas no processo do acoplamento oxidativo, considera-se além das reações catalíticas, as reações que ocorrem com alguns componentes na fase gasosa. Dessa forma, reformulando a equação 4.2, obtém-se a equação 4.3.

$$v \frac{\partial C_i}{\partial z} = \rho_b r_{c,i} + \varepsilon_b r_{g,i} \rightarrow \left[\frac{\text{mol}}{\text{m}^3 \text{s}} \right] \quad \text{Equação (4.3)}$$

A velocidade apresentada na equação 4.2 é descrita na equação 4.4.

$$v = \frac{\dot{V}}{A} \left[\frac{\text{m}}{\text{s}} \right] \quad \text{Equação (4.4)}$$

Cinética do reator

Os parâmetros cinéticos empregados neste estudo de caso foram apresentados anteriormente no artigo *“The oxidative coupling of methane on La₂O₃/CaO in a fixed-bed reactor”* (STANSCH, MLECZKO e BAERNS, 1997). O processo de acoplamento oxidativo é composto pelas 10 reações paralelas descritas nas Equações 3.1 - 3.10, conforme descrito na seção 3.

A partir das relações estequiométricas apresentadas nas Equações 3.1 a 3.10, considerando que ocorre o efeito de inibição promovido pelo oxigênio e o dióxido de carbono, a taxa reacional para a Equação 3.2 é descrita pela Equação 4.5.

$$r_2 = \frac{k_{0,2} e^{-\frac{E_{a,2}}{RT}} (K_{0,O_2} e^{-\frac{-\Delta H_{ad,O_2}}{RT}} \cdot p_{O_2})^{n_2} p_{CH_4}}{\left[1 + (K_{0,O_2} e^{-\frac{-\Delta H_{ad,O_2}}{RT}} \cdot p_{O_2})^n + K_{j,CO_2} e^{-\frac{-\Delta H_{ad,O_2}}{RT}} \cdot p_{O_2} \right]^2} \quad \text{Equação (4.5)}$$

Para as Equações 3.1 e 3.3 – 3.6 não ocorrerá o efeito de inibição causado pelo oxigênio, entretanto, haverá o efeito inibitório ocasional pelo dióxido de carbono. Dessa forma, o equacionamento utilizado para descrever a taxa dessas reações é apresentado abaixo.

$$r_{1,3-6} = \frac{k_{0,j} e^{-\frac{E_{a,j}}{RT}} p_c^{m_j} \cdot p_{O_2}^{n_j}}{\left(1 + K_{j,CO_2} e^{-\frac{\Delta H_{ad,CO_2}}{RT}} \cdot p_{CO_2}\right)^n} \quad \text{Equação (4.6)}$$

Para as demais reações, as taxas se dão da seguinte forma:

- Para a Equação 3.7:

$$r_7 = k_{0,7} e^{-\frac{E_{a,7}}{RT}} p_{C_2H_6} \quad \text{Equação (4.7)}$$

- Para as Equações 3.8 e 3.9:

$$r_{8-9} = k_{0,z} e^{-\frac{E_{a,z}}{RT}} P_z^{m_z} \cdot P_{H_2O}^{n_z} \quad \text{Equação (4.8)}$$

- Para a reação 3.10:

$$r_{10} = k_{0,10} e^{-\frac{E_{a,10}}{RT}} p_{CO_2}^{m_{10}} \cdot p_H^{n_{10}} \quad \text{Equação (4.9)}$$

Os parâmetros cinéticos (STANSCH, MLECZKO e BAERNS, 1997) empregados para a determinação de cada uma das taxas são observados na Tabela 1.

Tabela 1: Parâmetros cinéticos propostos pelo modelo de STANSCH, MLECZKO e BAERNS (1997)

R	$k_{0,j}$ $\text{mol.g}^{-1}.\text{s}^{-1}.\text{Pa}^{-\frac{1}{m+n}}$	$E_{a,j}$ kJ/mol	K_{j,CO_2} Pa^{-1}	$\Delta H_{ad,CO_2}$ kJ/mol	K_{O_2} Pa^{-1}	$\Delta H_{ad,O_2}$ kJ/mol	m_j	n_j
1	$0,20 \times 10^{-5}$	48	$0,25 \times 10^{-12}$	-175			0,24	0,76
2	23,5	182	$0,83 \times 10^{-13}$	-186	$0,23 \times 10^{-11}$	-124	1,0	0,40
3	$0,52 \times 10^{-6}$	68	$0,36 \times 10^{-13}$	-187			0,57	0,85
4	$0,11 \times 10^{-3}$	104	$0,40 \times 10^{-12}$	-168			1,0	0,55
5	0,17	157	$0,45 \times 10^{-12}$	-166			0,95	0,37
6	0,06	166	$0,16 \times 10^{-12}$	-211			1,0	0,96
7	$1,2 \times 10^{-7}$	226						
8	$9,3 \times 10^3$	300					9,7	0
9	$0,19 \times 10^{-3}$	173					1,0	1,0
10	$0,26 \times 10^{-1}$	220					1,0	1,0

4.1.2 Reforma a vapor do metano

Cinética do Reator

Considerando as reações do processo como sendo as apresentadas nas Equações 3.11, 3.12 e 3.13, para expressar a taxa de cada uma delas, tem-se o modelo de Langmuir-Hinshelwood, de acordo com ALVES (2005) e FROMENT e XU (1989), tendo como resultado as taxas de reações abaixo para cada respectiva reação:

$$r_1 = \frac{\left(\frac{k_1}{P_{H_2}^{2,5}} \left(p_{CH_4} p_{H_2O} - \frac{p_{H_2}^3 p_{CO}}{K_1} \right) \right)}{DEN^2} \quad \text{Equação (4.10)}$$

$$r_2 = \frac{\left(\frac{k_2}{P_{H_2}^{3,5}} \left(p_{CH_4} p_{H_2O}^2 - \frac{p_{H_2}^4 p_{CO_2}}{K_2} \right) \right)}{DEN^2} \quad \text{Equação (4.11)}$$

$$r_3 = \frac{\left(\frac{k_3}{P_{H_2}} \left(p_{CO} p_{H_2O} - \frac{p_{H_2} p_{CO_2}}{K_3} \right) \right)}{DEN^2} \quad \text{Equação (4.12)}$$

Sendo:

$$DEN = 1 + K_{CO} p_{CO} + K_{H_2} p_{H_2} + K_{CH_4} p_{CH_4} + \frac{K_{H_2O} p_{H_2O}}{p_{H_2}} \quad \text{Equação (4.13)}$$

Equacionamento do reator

O desenvolvimento das equações do reator é fundamentado no estudo de ALVES (2005), o qual o modelo fenomenológico validado usado para simulação dos dados se baseou, tendo adotado as hipóteses que a reação ocorre de modo isotérmico e a operação em regime permanente. As reações que ocorrem são as das Equações 3.11 e 3.12. A pressão parcial de cada componente está descrita nas equações abaixo:

$$p_{CH_4} = (1 - X_{CH_4})\sigma \quad \text{Equação (4.14)}$$

$$p_{CO_2} = X_{CO_2}\sigma \quad \text{Equação (4.15)}$$

$$p_{CO} = X_{CO}\sigma \quad \text{Equação (4.16)}$$

$$p_{H_2O} = (m - X_{H_2O})\sigma \quad \text{Equação (4.17)}$$

$$p_{CH_4} = (m_{H_2}^0 - X_{H_2})\sigma \quad \text{Equação (4.18)}$$

Sendo:

$$\sigma = \frac{P_{total}}{m_{H_2}^o + m + X_{H_2} - X_{CH_4} - X_{H_2O} + X_{CO_2} + X_{CO} + 1} \quad \text{Equação (4.19)}$$

Onde as frações dos componentes baseado em LIN *et al.* (2003) e ALVES (2005) são dadas por:

$$X_{CH_4} = 1 - \frac{F_{CH_4}}{F_{CH_4}^o} \quad \text{Equação (4.20)}$$

$$X_{CO_2} = \frac{F_{CO_2}}{F_{CH_4}^o} \quad \text{Equação (4.21)}$$

$$X_{CO} = \frac{F_{CH_4}}{F_{CH_4}^o} \quad \text{Equação (4.22)}$$

$$X_{H_2O} = 1 - \frac{F_{H_2O}}{F_{CH_4}^o} \quad \text{Equação (4.23)}$$

$$X_{H_2} = \frac{F_{H_2}}{F_{CH_4}^o} \quad \text{Equação (4.24)}$$

A variação da conversão de cada componente ao longo do reator foi baseada em ALVES (2005) e está disposta nas equações de balanço de massa abaixo:

$$\frac{dX_{CH_4}}{dz} = \frac{W}{F_{CH_4}^o} (r_1 + r_2) \quad \text{Equação (4.25)}$$

$$\frac{dX_{CO_2}}{dz} = \frac{W}{F_{CH_4}^o} (r_2 + r_3) \quad \text{Equação (4.26)}$$

$$\frac{dX_{CO}}{dz} = \frac{W}{F_{CH_4}^o} (r_1 - r_3) \quad \text{Equação (4.27)}$$

$$\frac{dX_{H_2O}}{dz} = \frac{W}{F_{CH_4}^o} (r_1 + r_2 + r_3) \quad \text{Equação (4.28)}$$

$$\frac{dX_{H_2}}{dz} = \frac{W}{F_{CH_4}^o} (3r_1 + r_3 + 4r_2) - \frac{dY_{H_2}}{dz} \quad \text{Equação (4.29)}$$

Sendo a taxa de permeação do hidrogênio na membrana, também baseado em ALVES (2005), dada pela Equação 4.30:

$$\frac{dY_{H_2}}{dz} = \frac{2\pi R_m L \beta}{F_{CH_4}^o} (P_{H_2}^{0,5} + P_P^{0,5}) \quad \text{Equação (4.30)}$$

4.2 Geração dos dados

4.2.1 Acoplamento oxidativo do metano (OCM)

Os dados utilizados para o desenvolvimento do modelo de predição empregados neste estudo de caso foram simulados em Python. Para gerar a matriz contendo os dados, utilizou-se a função *random.uniform()* da biblioteca *Numpy*, de onde obtêm-se amostras aleatórias de uma distribuição uniforme, retornando amostras aleatórias com um *array*. O modelo usado para a geração de dados é um modelo fenomenológico e foi validado com dados da literatura, e cada um dos limites estabelecidos para a geração destes, podem ser observados na Tabela 2.

O desenvolvimento do modelo foi realizado com base no processo OCM em PFR, com cinco variáveis de entrada (inputs): fração molar de alimentação de CH_4 , razão molar de alimentação CH_4/O_2 , temperatura, pressão do sistema e vazão volumétrica STP (válvula de pistão); e sete variáveis de saída (outputs): conversão de O_2 , conversão de CH_4 , seletividade de C2, rendimento de C2, rendimento de C_2H_6 , rendimento de CO_2 e rendimento de CO. Na elaboração do modelo, considerou-se um processo em estado estacionário e isotérmico, levando em consideração a existência de reações na fase gasosa, além das reações catalíticas.

Tabela 2: Intervalo da variável no gerador de dados para o processo OCM

Variáveis de entrada	Intervalo
Fração molar de alimentação de CH_4	0,4 - 0,95
Razão molar de alimentação CH_4/O_2	2 - 17
Temperatura (K)	973 - 1173
Pressão (kPa)	100 - 120
Vazão volumétrica STP	4×10^{-6} - 13×10^{-4}

Uma exemplificação de como ficou o código nesta etapa é apresentado na Figura 3.

```
In [5]: n = 6
s,e = 0.4,0.95 # start & end <fração molar de alimentação de metano>
fCH4 = np.random.uniform(low=s, high=e, size=n) #amostra uniformemente distribuída
s,e = 2,17 # razão molar de alimentação metano/oxigênio
CH4_O2 = np.random.uniform(low=s, high=e, size=n)
s,e = 699.85+273.15,899.85+273.15 #limites de variação de temperatura
T = np.random.uniform(low=s, high=e, size=n)
s,e = 100e3,110e3 #limites de variação da pressão
P = np.random.uniform(low=s, high=e, size=n)
s,e = 4e-6,13e-4 # limites variação da vazão volumétrica STP
vzstp = np.random.uniform(low=s, high=e, size=n)
```

Figura 3: Geração da base de dados

4.2.2 Reforma a vapor do metano

Partindo de um modelo fenomenológico já validado do processo de reforma a vapor do metano em reator de membrana, utilizou-se a função *Random* da biblioteca *Numpy*, foram geradas 5 variações para cada variável de entrada dentro do intervalo retirado como referência de BERNARDES (2009) e WARD e DAO (1999). O intervalo está descrito na Tabela 3. Cada condição simulada na entrada foi aplicada ao simulador obtendo assim uma grande base de dados para o processo.

O desenvolvimento da simulação foi realizado com base no processo da reforma a vapor do metano, tendo como variáveis de entrada: vazão molar inicial de metano (FCH_4), vazão molar inicial de dióxido de carbono (FCO_2), vazão molar inicial de água (FH_2O), vazão molar inicial de hidrogênio (FH_2), vazão molar inicial de nitrogênio (FN_2), pressão inicial (P) e temperatura inicial (T).

Tabela 3: Intervalo da variável no gerador de dados para o processo de reforma a vapor

Variável de entrada	Intervalo
FCH_4 (Kgmol/h)	5 - 6.2
FCO_2 (Kgmol/h)	0.2 - 0.35
FH_2O (Kgmol/h)	16 - 20
FH_2 (Kgmol/h)	0.45 - 0.7
FN_2 (Kgmol/h)	0.78 - 0.920
P (bar)	26 - 31
T (K)	850 - 920

A fim de simplificar a predição dos dados, FN_2 deixou de ser uma variável de entrada na base de dados, uma vez que o Nitrogênio é um gás inerte. As variáveis FCH_4 e FCO_2 deram origem à uma variável: razão da vazão molar inicial de dióxido

de carbono por metano (FCO_2O/FCH_4O). Sendo assim, foram estabelecidos que as variáveis de entrada seriam 4 e 7 de saída, estando estas listadas abaixo na Tabela 4.

Tabela 4: Variáveis de entrada e saída do processo de reforma a vapor

Variáveis de entrada (X)	Variáveis de saída (Y)
FH ₂ O – Vazão molar inicial de hidrogênio (Kgmol/h)	XCH ₄ – Fração molar de metano
FCO ₂ O/CH ₄ O – razão da vazão molar inicial de dióxido de carbono por metano	XCO ₂ – Fração molar de dióxido de carbono
P0 – Pressão inicial (bar)	FH ₂ – Vazão molar de hidrogênio (Kgmol/h)
T0 – Temperatura inicial (K)	FH ₂ w – Vazão molar de hidrogênio no permeado (Kgmol/h)
	FCH ₄ – Vazão molar de metano (Kgmol/h)
	FCO ₂ – Vazão molar de dióxido de carbono (Kgmol/h)
	P – Pressão final (bar)

4.3 Desenvolvimento de Modelos de aprendizagem de máquinas

O modelo de aprendizagem de máquina Random Forest foi selecionado para relacionar as variáveis de entrada aos outputs de interesse do processo acoplamento oxidativo do metano. A escolha deste modelo para o desenvolvimento do algoritmo se deu por conta de sua simplicidade e eficácia, visto que, o *Random Forest* baseia-se na formação de uma floresta aleatória composta por diversas árvores de decisão aleatórias, que ao final do processo, conceberam resultados representativos de um todo. Com o intuito de facilitar e automatizar parte da busca pelo melhor modelo de regressão para este caso de estudo, criou-se um programa em Python, contendo seções de pré-processamento de dados, treinamento e validação e por fim, a simulação dos modelos de *random forest* direto com o conjunto de teste

Para o processo de reforma a vapor, após a tentativa inicial de aplicar o *Random Forest* ao modelo ter demonstrando baixa confiabilidade de predição, o algoritmo de aprendizagem de máquinas *XGBoost* foi selecionado para este caso, porque assim como o RF ele tem como base árvores de decisão com o diferencial de

também ter como base o algoritmo de aumento de gradiente que minimiza as perdas conforme novos modelos são criados. A flexibilidade em definir e sintonizar hiperparâmetros também favorece o ajuste às necessidades do problema.

O aumento de árvores é um efetivo e conhecido método de aprendizagem de máquinas para obter métricas boas quando apenas o algoritmo de Random Forest não é capaz de se ajustar ao modelo, além do mais, o algoritmo foi reconhecido por ter mostrado um ótimo desempenho em competições que envolviam a resolução de problemas de natureza física e previsão de risco (CHEN e GUESTIN, 2016).

Ambos os modelos são modelos não paramétricos, isto é, aprendem diretamente a partir dos dados, permitindo uma maior flexibilidade em termos de como as variáveis são relacionadas entre si. Isso os torna particularmente úteis em situações em que as relações entre variáveis são complexas e difíceis de modelar de forma paramétrica (ALPAYDIN, 2010; HASTIE, TIBSHIRANI e FRIEDMAN, 2019).

4.3.1 Pré-processamento dos dados

Os conjuntos de dados gerados (*dataset*) pelos modelos fenomenológicos foram avaliados a fim de verificar se havia dados faltantes, irreais e *outliers*, e também foi necessário avaliar a correlação entre as variáveis por meio da correlação de Spearman.

A conferência dos dados faltantes foi realizada por meio da biblioteca *Missingno* que é nativo do próprio Python, permitindo que seja observado a presença de dados faltantes em forma de disposições. Neste estudo de caso em particular, utilizou-se o *missingno.matrix()* que retorna uma matriz.

Para avaliar a relação entre as variáveis de saída e as variáveis de entrada empregou-se a análise estatística conhecida como correlação de Spearman, método não paramétrico que não pressupõe uma distribuição normal dos dados (HAUKE e KOSSOWSKI, 2011). Esta medida exprime a correlação em duas variáveis e retorna um valor que varia entre -1 a 1, quanto mais próximo das extremidades, mais forte será a correlação entre as duas variáveis. Se o valor estiver mais próximo da extremidade negativa, observa-se que o aumento de uma variável provoca a redução da outra; no caso do extremo positivo, o aumento de uma variável implica no aumento da outra. Para valores próximos a 0, a força da correlação pode ser denominada como fraca ou inexistente. Os valores apresentados da correlação de Spearman para ambos os estudos de caso serão apresentados ao decorrer dos itens 5.1 e 5.2.

4.3.2 Treinamento e validação do modelo

Para esta etapa, os *datasets* gerados tiveram os seus dados separados em 3 conjuntos: treino, validação e teste. Os dados de treino são usados para treinar o modelo, os dados de teste são usados para avaliar a performance do modelo e os dados de validação são usados para ajustar os hiperparâmetros do modelo. O objetivo é criar um modelo que possa generalizar bem para dados que não foram usados no processo de treinamento. Para os modelos analisados neste estudo de caso, utilizou-se 90 % dos dados gerados do dataset para treino e 10 % para teste. Além disso, utilizou-se um conjunto de validação composto por 20% dos dados do conjunto de treino para avaliar o desempenho do modelo durante o treinamento e ajustar os hiperparâmetros. Isso corresponde a 20% dos dados utilizados no conjunto de treino, que representa 90% do total de dados gerados do dataset.

4.3.3 Regressão via Random Forest

Numa primeira abordagem para o modelo direto, as entradas foram utilizadas para prever todas as saídas, disponíveis na Tabela 5, de uma só vez no nosso modelo de regressão, utilizando uma tolerância de 100 tentativas e os valores disponíveis na Tabela 6 para a otimização de Optuna. Posteriormente, no entanto, foi realizada outra simulação, obtendo-se uma única saída de cada vez. Foi aplicada a mesma configuração da abordagem anterior.

Tabela 5 :Variáveis de entrada e saída usadas no modelo RF para o processo OCM

Variáveis de entrada (X)	Variáveis de saída (Y)
Fração molar de alimentação de CH ₄	Conversão O ₂
Razão molar de alimentação CH ₄ /O ₂	Conversão CH ₄
Temperatura (K)	Seletividade C ₂
Pressão (kPa)	Rendimento C ₂
Vazão volumétrica STP	Rendimento C ₂ H ₆
	Rendimento CO ₂
	Rendimento CO

Para a construção desse modelo de regressão foi utilizado o *RandomForestRegressor* disponível na biblioteca *Scikit-learn*, no qual se estabelece os hiperparâmetros para a criação das árvores da RF. Para estimar os melhores valores para cada um dos hiperparâmetros, neste caso também foi empregado o *Optuna*, um método de otimização bayesiano.

O *Optuna* é um otimizador poderoso que permite que sejam escolhidos quais os parâmetros serão estimados, seguindo o princípio de *define-by-run* e o intervalo no qual este estudo deverá ser realizado, seguindo o princípio de *parameter search-space* (DIEDERICH, 1992).

Os hiperparâmetros estimados e seus respectivos intervalos de estudos estão expressos na Tabela 6.

Tabela 6: Dados de estudo no Optuna para o processo OCM

Biblioteca	Tipos de hiperparâmetros	Hiperparâmetros	Search-space
	Preditor base	Árvore de decisão	-
Optuna	A quantidade mínima de folhas para uma árvore	min_samples_leaf	1 - 10
	O número de árvores na floresta	n_estimators	10 - 400
	A profundidade máxima da árvore	max_depth	0.001 - 0.1

A avaliação do desempenho do modelo foi obtida também através do coeficiente de determinação (R^2), que compara o seu modelo com um modelo ingênuo que sempre prevê a média e segue a formulação da Equação 4.31 (QUININO, REIS e BESSEGATO, 2013), e da raiz do erro quadrático médio (RMSE), que por ser de grandeza quadrática penaliza erros grandes e é descrito nas unidades da variável alvo sendo uma boa métrica para percepção humano sobre o modelo, este é descrito pela Equação 4.32 (CHAI e DRAXIER, 2014) (WANG e LU, 2018):

$$1 - \frac{\sum_{i=1}^N (\text{Predito}_i - \text{Real}_i)^2}{\sum_{i=1}^N (\text{Predito}_i - \text{Média de todos os valores}_i)^2} \quad \text{Equação (4.31)}$$

$$\sqrt{\frac{\sum_{i=1}^N (Predito_i - Real_i)^2}{N}} \quad \text{Equação (4.32)}$$

4.3.4 Regressão via XGBoost

Para a predição dos valores de saída, em uma primeira abordagem na forma direta, foi utilizado o modelo de regressão descrito no item 4.3.1, onde dada as variáveis de entrada, era possível prever por vez uma variável de saída. Para tal foi utilizada uma tolerância de 100 tentativas para a otimização. As variáveis de saída e entrada foram especificadas anteriormente na Tabela 5.

Para a construção do modelo de regressão foi utilizado o *XGBRegressor* disponível na biblioteca *XGBoost*, no qual deve-se estabelecer os valores dos hiperparâmetros para criação do regressor. Para estimar os melhores valores para cada hiperparâmetro foi empregado o *Optuna*. Os hiperparâmetros estimados e seus respectivos intervalos de estudos estão expressos na Tabela 7.

Tabela 7: Dados do Optuna para o processo de reforma a vapor

Biblioteca	Tipos de hiperparâmetros	Hiperparâmetros	Search-space
	Preditor base	Árvore de decisão	-
	Soma do peso da amostra dos nós	min_child_weight	1 - 10
Optuna	O número de árvores na floresta	n_estimators	10 - 400
	Peso de cada passo da iteração	learning_rate	0.001 - 0.1
	A profundidade máxima da árvore	max_depth	2 - 10

A avaliação do desempenho do modelo foi obtida através do coeficiente de determinação (R^2), da raiz do erro quadrático médio (RMSE), cujas fórmulas foram definidas anteriormente pelas equações 4.31 e 4.32 respectivamente.

5. RESULTADOS

5.1 Random Forest

Os dados gerados pelo modelo fenomenológico validado são apresentados na Figura 4, que contém os valores de cada uma das variáveis de entrada e saída dentro do intervalo proposto na Tabela 2, que são considerados como os intervalos ótimos de reação segundo STANSCH, MLECZKO e BAERNS, 1997. Foram totalizadas 7.776 simulações ao final da geração de dados, seguindo o procedimento de segmentação de dados descrito no item 4.3.1. Na Tabela 8, tem-se a relação numérica de simulações para treinamento, validação e teste do modelo.

	f_CH4	CH4/O2	T	P	vz_STP	XO2	XCH4	SC2	YC2	YC2H6	YCO2	YCO
0	0.437462	11.888153	1109.279931	1.070886	0.000044	9.964640	1.435450	69.827519	1.002339	0.974944	0.146094	0.287016
1	0.437462	11.888153	1109.279931	1.070886	0.000165	2.669997	0.396405	70.621328	0.279946	0.276812	0.037637	0.078822
2	0.437462	11.888153	1109.279931	1.070886	0.000520	0.844880	0.126125	70.675142	0.089139	0.088761	0.011750	0.025235
3	0.437462	11.888153	1109.279931	1.070886	0.000782	0.562215	0.083986	70.672720	0.059355	0.059181	0.007801	0.016830
4	0.437462	11.888153	1109.279931	1.070886	0.000714	0.615888	0.091992	70.673448	0.065014	0.064806	0.008550	0.018428
...	...	...	...	...	...	...	...	...	...	...	...	...
7771	0.643734	3.121787	993.294745	1.040646	0.000165	0.746631	0.228943	25.278256	0.057873	0.057678	0.054135	0.116934
7772	0.643734	3.121787	993.294745	1.040646	0.000520	0.238228	0.073139	25.276897	0.018487	0.018466	0.017089	0.037563
7773	0.643734	3.121787	993.294745	1.040646	0.000782	0.158706	0.048734	25.276508	0.012318	0.012308	0.011366	0.025050
7774	0.643734	3.121787	993.294745	1.040646	0.000714	0.173820	0.053373	25.276590	0.013491	0.013479	0.012452	0.027430
7775	0.643734	3.121787	993.294745	1.040646	0.000359	0.344986	0.105881	25.277295	0.026764	0.026720	0.024802	0.054315

7776 rows × 12 columns

Figura 4: Dataset gerado através do modelo fenomenológico para o processo OCM

Tabela 8: Descrição numérica do modelo *Random Forest*

	Nº de simulações	Nº total de dados
Treino	5.599	67.188
Teste	778	9.336
Validação	1.399	16.788

A partir do *dataset* gerado, foi possível obter a correlação de Spearman relacionando as variáveis de entrada e saída. O resultado obtido é apresentado na Figura 5.




Figura 5: Correlação de Spearman para o processo OCM (as AUTORAS)

Avaliando os valores apresentados na Figura 5, é possível notar as maiores correlações (considerando os valores obtidos que sejam maiores ou iguais à 0,4 entre os pares) entre as entradas e saídas. As variáveis com maior peso dentro do processo são a razão molar de alimentação CH_4/O_2 , temperatura, pressão e a vazão volumétrica. Quando o valor resultante da correlação de Spearman é positivo, o aumento do valor da variável de entrada implica em um aumento na variável de saída, ou seja, um incremento na condição inicial dessas variáveis influencia diretamente no aumento na variável de saída correlacionada com a mesma. Quando o valor resultante da correlação de Spearman é negativo, a variável de entrada influencia de forma inversa à saída. Assim, se a condição inicial aumentar, irá diminuir a variável de saída a qual tem correlação.

Em uma primeira abordagem, a simulação do modelo RF visava a predição de todas as variáveis de saída ao mesmo tempo, em uma estrutura de modelo MIMO (isto é, do inglês, múltiplas entradas, múltiplas saídas). As variáveis de entrada utilizadas nas simulações iniciais foram a fração molar de CH_4 , razão molar de alimentação CH_4/O_2 , temperatura, pressão e vazão volumétrica de gás; os limites

estabelecidos para estas entradas foram mostrados na Tabela 2. As saídas de interesse nessa abordagem eram a conversão de O_2 e CH_4 ; seletividade de C_2 ; rendimento de C_2 , C_2H_6 , CO_2 e de CO . Considerando essa primeira configuração do modelo RF, um dos resultados obtidos é apresentado pelas métricas mostradas na Tabela 9.

Tabela 9: Métricas de uma das simulações do processo OCM

	R^2	RMSE
Treino	0,8424	2,8474
Validação	0,7695	3,5697
Teste	0,7596	3,5067

Avaliando os valores apresentados na Tabela 9, é possível observar que o R^2 mostrou valores muito diferentes entre treinamento, validação e conjunto de dados de teste. O R^2 do treinamento mostra que o modelo foi capaz de aprender o processo, porém, para validação e teste, os valores de R^2 foram ligeiramente inferiores ao treinamento, o que sugere a presença de *overfitting*, fenômeno que ocorre quando o modelo não generaliza tão bem para novos dados de entrada. Na Tabela 10, tem-se as demais métricas empregadas na avaliação o modelo.

Tabela 10: Desvio padrão, variância e RMSE da simulação considerando a predição de todas as variáveis de saída

Métricas	Variáveis						
	XO2	XCH4	SC2	YC2	YC2H6	YCO2	YCO
Desvio padrão	2,6540	0,5055	14,3558	0,3091	0,3019	0,0677	0,1482
Variância	7,0435	0,2555	206,0889	0,0956	0,0912	0,0046	0,0219
RMSE^v	3,5697						
RMSE^t	3,5067						

v - Valores do conjunto de dados de validação; t- Valores do conjunto de dados de teste.

Para os valores expressos na Tabela 10, pode-se observar que tanto para a validação quanto para o teste, os valores de RMSE fornecidos pelo mesmo modelo foram maiores que o desvio padrão das variáveis de saída do conjunto de dados, com exceção do SC2. Isso indica que o modelo não está prevendo muito bem os valores de saída para a maioria dos processos, mas está fazendo isso de forma mais precisa para o processo SC2. Entretanto, essa observação pode ser uma afirmação falsa, tendo em vista que as demais métricas avaliadas também não tiveram um bom desempenho. O RMSE é uma forma simplificada de avaliar o modelo que pode ser descrito como uma medida do desvio dos valores simulados em relação aos valores reais, obtidos como a raiz quadrada do desvio médio quadrático. Consequentemente, um valor RMSE maior que o desvio padrão do output implica a presença de outliers, o que leva ao aumento do peso da métrica e afeta a resposta do modelo.

Portanto, a resposta do modelo de RF para a predição de todas as variáveis ao mesmo tempo, apresentada nas Tabelas 9 e 10, não pode ser considerada adequada devido às métricas obtidas em resposta das simulações. Ademais, a baixa correlação entre alguns pares de variáveis também deve ser levada em consideração, como pôde ser observado na Figura 5, nem todas as variáveis de entradas possuem uma boa resposta em relação a variável de saída, segundo a correlação de Spearman.

Após a baixa resposta do modelo RF inicial, optou-se por mudar a configuração de saída do modelo. Nessa segunda abordagem, foram consideradas as mesmas variáveis de entrada da simulação anterior, entretanto, com foco em um produto de cada vez, em uma estrutura de modelo de múltiplas entradas e uma única saída (em inglês, MISO). Ao analisar as métricas resultantes das novas simulações, foi possível observar uma melhora significativa quando comparado com os valores obtidos anteriormente nas Tabelas 9 e 10, como por exemplo a redução do RMSE e um aumento do R^2 .

As métricas obtidas da segunda configuração do modelo são apresentadas nas Tabelas 11 e 12.

Tabela 11: Métricas do modelo RF obtidas para XO2, XCH4 e YC2

	XO2		XCH4		YC2	
	R ²	RMSE	R ²	RMSE	R ²	RMSE
Treino	0,9999	0,0248	0,9999	0,0062	0,9999	0,0026
Validação	0,9993	0,0588	0,9996	0,0135	0,9994	0,0075
Teste	0,9994	0,0639	0,9992	0,0173	0,9997	0,0063

Tabela 12: Desvio padrão, variância e RMSE para as variáveis de saída preditas usando o modelo RF

Métricas	Variáveis						
	XO2	XCH4	SC2	YC2	YC2H6	YCO2	YCO
Desvio padrão	2,3737	0,6178	13,4433	0,3197	0,3116	0,1066	0,2070
Variância	5,6345	0,3817	180,7223	0,1022	0,0971	0,0114	0,0428
RMSE^v	0,0588	0,0135	0,0363	0,0075	0,0069	0,0029	0,0059
RMSE^t	0,0639	0,0173	0,0354	0,0063	0,0068	0,0024	0,0065

v - Valores do conjunto de dados de validação; t- Valores do conjunto de dados de teste.

Avaliando as métricas da Tabela 11, é possível notar uma melhora em relação aos valores de R² em cada termo avaliado. A Tabela 12 mostra o desvio padrão, variância e RMSE dos modelos de RF que têm uma única saída, onde nota-se uma redução dos valores de RMSE em comparação com os mostrados na Tabela 9 apresentada anteriormente, implicando em um menor desvio entre os valores simulados pelo modelo e os valores reais. Valores mais baixos de RMSE resultam em um modelo melhor, uma vez que é uma métrica orientada negativamente, ou seja, quanto menor for o seu valor, melhor será o ajuste do modelo.

Com base nos dados reais do *dataset* e os valores simulados pelo modelo RF, foram plotados gráficos de dispersão para avaliar a precisão do modelo de aprendizado de máquina. O eixo x apresenta o valor real (Y_{test}), enquanto o eixo y (Y_{test_pred}) apresenta a previsão feita pelo modelo. Uma reta central foi traçada

para representar a relação ideal entre o valor real e a previsão, como pode ser visto na Figura 6.




Figura 6: Dados simulados versus dados originais. Onde: A) XO₂, B) XCH₄, C) SC₂, D) YC₂, E) YC₂H₆, F) YCO₂ e G) YCO

Ao analisar os gráficos, nota-se que a maioria dos pontos se encontram densamente compactados em torno da reta central, indicando que o modelo está produzindo previsões precisas. Isso é uma boa notícia e sugere que o modelo foi bem treinado e está apto a prever valores com uma boa margem de acurácia. Os gráficos concordam com o apontamento das métricas R^2 e RMSE de maneira que usados em conjunto permitem uma compreensão mais abrangente da eficácia do modelo.

Vale ressaltar, que foi feita uma terceira abordagem utilizando a configuração MISO com o modelo XGBoost, seguindo os mesmos conceitos e parâmetros da simulação MISO com o RF citada anteriormente. As métricas obtidas entre os dois modelos possuíam valores próximos, porém o RF foi escolhido para este estudo de caso por demandar menos esforço computacional, além de ter se mostrado uma ferramenta poderosa e eficaz para um dos processos mais complexos da engenharia química.

Em resumo, as métricas avaliadas, a correlação de Spearman e os gráficos indicam que o modelo RF de aprendizado de máquina apresentou uma boa eficácia na realização de previsões. Isso sugere que ele pode ser uma ferramenta útil na solução de problemas práticos. No entanto, é importante continuar monitorando o desempenho do modelo para assegurar sua precisão e tomar medidas corretivas caso sejam necessárias.

5.2 XGBoost

Na Figura 7, tem-se a visualização do *dataset* obtido através da simulação no modelo fenomenológico validado nos intervalos descritos na Tabela 3. Tais dados foram tratados e as simulações que tinham dados irreais tal qual valores negativos ou frações molares cujo valor era superior a 1 foram descartados. Por fim foram totalizadas 33.895 simulações, cada uma armazenando 11 dados das variáveis. Seguindo a divisão descrita no item 5.4 na seção de metodologia, na Tabela 13 tem-se a relação numérica de simulações para treinamento, validação e teste do modelo.

	FH20	FCO20/FCH40	P0	T0	XCH4	FH2w	FH2	XC02	P	FCH4	FCO2
0	0.562151	0.051891	28.109464	871.161641	0.884378	18.899040	0.000007	0.936262	19.982631	0.580963	4.704395
1	0.562151	0.051891	28.109464	866.536728	0.795748	17.117706	0.000008	0.847633	19.319097	1.026297	4.259066
2	0.562151	0.051891	27.828824	871.161641	0.872611	18.662548	0.000008	0.924495	19.485278	0.640086	4.645273
3	0.562151	0.051891	27.828824	866.536728	0.780325	16.807734	0.000008	0.832211	18.798777	1.103791	4.181573
4	0.562151	0.051891	27.949258	871.161641	0.877768	18.766186	0.000008	0.929652	19.700137	0.614176	4.671182
...	...	...	...	...	...	...	...	...	...	...	...
33890	0.464311	0.046582	27.949258	866.536728	0.768043	18.436468	0.000006	0.814619	20.841740	1.321892	4.642403
33891	0.464311	0.046582	28.625074	871.161641	0.880155	20.992109	0.000005	0.926730	22.627535	0.682980	5.281308
33892	0.464311	0.046582	28.625074	866.536728	0.799996	19.164856	0.000006	0.846572	21.974229	1.139795	4.824499
33893	0.464311	0.046582	29.445540	871.161641	0.905300	21.565304	0.000005	0.951875	23.888461	0.539681	5.424605
33894	0.464311	0.046582	29.445540	866.536728	0.834174	19.943951	0.000005	0.880749	23.287988	0.945021	5.019271

33895 rows x 11 columns

Figura 7: *Dataset* gerado através do modelo fenomenológico para o processo de reforma a vapor

Tabela 13: Descrição numérica do modelo XGBoost

	Nº de simulações	Nº total de dados
Treino	24.404	268.444
Teste	3.390	37.290
Validação	6.101	67.111

Para análise da correlação entre as variáveis do processo, assim como para o modelo de Random Forest, foi utilizado o gráfico com a correlação de Spearman, disponível abaixo na Figura 8.




Figura 8: Correlação de Spearman para o processo de reforma a vapor do metano (as AUTORAS)

Através da relação do gráfico da correlação de Spearman, é possível afirmar que a variável de entrada que tem maior impacto para determinação das variáveis de saída do processo é a temperatura inicial, tal informação vai em concordância com a natureza do processo. O incremento da Temperatura inicial (T0) influencia para aumento do Fluxo de Hidrogênio no permeado (FH₂W), do Fluxo de dióxido de carbono (FCO₂), na Fração Molar de dióxido de carbono (XCO₂) e na Pressão. Já para o Fluxo de metano, Fração molar de metano (FCH₄) e para o Fluxo de Hidrogênio no meio reacional (FH₂), a correlação apresenta um valor negativo, indicando que o incremento da variável de entrada analisada influencia na diminuição do valor destas

ao fim do processo. A segunda variável de entrada a se analisar é a pressão inicial (P_0), esta apesar de ter correlação diferente de 0 para com as variáveis de saída apresenta uma influência extremamente fraca nos resultados quando comparado com a temperatura inicial, influenciando de forma moderada apenas a pressão final.

Para a razão entre fluxos iniciais de dióxido de carbono por metano (FCO_2O/FCH_4O), a influência é desprezível para quase todas as variáveis, tal resultado segue em concordância com o fato visto que independente do fluxo ser alto a reação não irá ocorrer se não estiver em uma temperatura inicial ideal, a mesma lógica pode ser aplicada ao fluxo inicial de hidrogênio (FH_2O).

Com base em testes preliminares e na experiência do desenvolvimento dos modelos anteriores, para o *XGBoost* optou-se pela estrutura de modelo MISO, com múltiplas entradas e uma saída por vez.

A determinação dos intervalos dos hiperparâmetros foi realizada empiricamente, tendo como referência outros modelos do mesmo algoritmo aplicado à resolução de problemas complexos. Para cada uma das variáveis os valores para os melhores parâmetros estão dispostos na Tabela 14.

Tabela 14: Melhores valores para os hiperparâmetros do modelo *XGBoost* por variável

	N_estimators	Max_depth	Min_child_weight	Learning_rate
XCH4	342	3	1	0,09457063
FH2w	266	4	10	0,06187435
XCO2	375	3	1	0,09673835
P	194	2	10	0,04876721
FCH4	355	4	1	0,05519967
FCO2	351	6	9	0,05427770

O coeficiente de determinação (R^2) dos dados de treino, teste e validação para cada uma das variáveis de saída está explícito na Tabela 15. Quanto mais próximo de 1, maior a capacidade do modelo de explicar a variância dos dados, descartando a possibilidade de *underfitting*, isto é, quando um modelo não é capaz de captar os padrões e relações subjacentes entre as características de entrada e a variável de saída nos dados de formação resultando em um modelo que é demasiado simples ou

demasiado rígido e não generaliza bem os novos dados (HASTIE, TIBSHIRANI e FRIEDMAN, 2019). No geral, todas as variáveis obtiveram um valor para o R^2 superior a 0,9 traduzindo uma precisão alta, com exceção para a determinação da Pressão ao fim do processo, o modelo não se apresentou acurado e, portanto, confiável. Outro parâmetro de análise é a relação entre si do R^2 para treino, teste e validação, espera-se que o R^2 de treino seja superior aos demais para diminuir a possibilidade de *overfitting*, tal hipótese foi atingida para todas as variáveis menos para o FH₂W.

Tabela 15: Valores do coeficiente de determinação do modelo

	XCH4	FH2W	XCO2	P	FCH4	FCO2
	R^2					
Treino	0,9751	0,9724	0,9750	0,5455	0,9767	0,9813
Validação	0,9748	0,9807	0,9736	0,5411	0,9763	0,9409
Teste	0,9741	0,9804	0,9744	0,5426	0,9761	0,9805

Outra métrica de avaliação é o RMSE, pela natureza de sua fórmula ser quadrática, conforme há o aumento da ocorrência de erro, o RMSE aumenta de forma considerável. Em todas as variáveis dos *datasets* de treino, validação e teste o RMSE foi bem baixo, como pode ser observado na Tabela 16, excluindo a presença de *outliers*, e quando comparado ao desvio padrão das variáveis no *dataset*, possuem valores inferior ao do desvio padrão, demonstrando uma boa acurácia do modelo.

Tabela 16: Valores de RMSE, variância e desvio padrão do modelo XGBoost

Métricas	Variáveis					
	XCH4	FH2W	XCO2	P	FCH4	FCO2
Desvio padrão	0,0821	1,9500	0,0825	1,6563	0,4520	0,4875
Variance	0,0067	3,8027	0,0068	2,7433	0,2043	0,2377
RMSE^{tr}	0,0090	0,2412	0,0090	0,9205	0,0489	0,0487
RMSE^v	0,0091	0,1986	0,0091	0,9088	0,0493	0,0879
RMSE^t	0,0092	0,1983	0,0091	0,9011	0,0494	0,0497

v - Valores do conjunto de dados de validação; t- Valores do conjunto de dados de teste; tr- Valores do conjunto de dados de treino

Uma forma alternativa de analisar a correlação entre os dados é através do *plot* confrontando os dados preditos e os reais. Através da Figura 9 é possível observar a relação entre os dados reais, no eixo das abscissas tendo como base os valores de teste preditos pelo modelo ($Y_{Test_predito}$) e os valores reais do *dataset* (Y_{Test}) no eixo das ordenadas para cada uma das variáveis de saída. A reta traçada indica a razão de relação entre os valores, quanto mais próximos, melhor foi o ajuste do modelo.




Figura 9: Dados preditos versus dados originais. Onde: A) XCH4, B) FH2w C) XCO2, D) P, E) FCH4, F) FCO2

Todas as variáveis de saída apresentaram um padrão de comportamento satisfatório, estando razoavelmente compactadas em torno da reta central, com exceção da variável de Pressão. Esta, conforme foi demonstrado através do valor obtido para o coeficiente de determinação anteriormente, apresentou um pior desempenho de ajuste ao modelo. Uma hipótese possível para explicar este fato pode residir na seleção do intervalo definido para gerar a base de dados simulados, não tendo sido ampla o suficiente para que a variável influenciasse com maior intensidade os dados de saída.

6. CONCLUSÃO

A aplicação e exploração dos dois algoritmos de aprendizagem de máquinas a dois processos de grande importância na indústria petroquímica foi bem sucedida. O *Random Forest* provou ser uma ferramenta poderosa e eficaz capaz de ser utilizada em um dos processos mais complexos e problemáticos dessa indústria, assim como *XGBoost* demonstrou alta acurácia, sendo assim um modelo confiável a ser replicado e uma excelente alternativa à modelos com correlações complexas onde o *Random Forest* não apresenta alto desempenho. Ambos os algoritmos podem ser usados como base para resolução de questões de modelagem de engenharia, com o benefício da redução do custo experimental dos processos.

Para *Random Forest* a previsão de variáveis individualmente foi uma grande melhoria no desempenho do modelo, os resultados obtidos apresentaram um R^2 acima de 0,99 para os conjuntos de treino, validação e teste de todas as variáveis de saída. Embora já exista um modelo fenomenológico que descreve o processo OCM, é uma vantagem competitiva ter um modelo *Random Forest* eficiente e/ou um conjunto de modelos de *Random Forest* (utilizando a estratégia de um *output* único), uma vez que ML são modelos não paramétricos.

Para o *XGBoost*, como foi adotado o modelo MISO desde o primeiro momento, favoreceu que o modelo obtivesse um alto desempenho nas primeiras tentativas de sintonização de uma boa janela de busca dos melhores valores para os hiperparâmetros. Para o modelo, com exceção da pressão que obteve um R^2 geral de 0,54, as demais variáveis obtiveram um R^2 acima de 0,97 para os conjuntos de teste, treino e validação.

Assim, os modelos de aprendizagem de máquinas utilizados se mostraram robustos suficientes e depois de treinados podem ser usados como ferramentas de monitoramento e controle online em instalações industriais.

7. TRABALHOS FUTUROS

- Explorar a relação da Pressão com o processo com o objetivo de melhorar suas métricas de predição.
- Aplicar melhorias no modelo OCM, com por exemplo, a incorporação de dados tridimensionais do reator em vez de um modelo 1D. Usando dados 3D, o modelo seria capaz de capturar informações mais detalhadas sobre o reator e, portanto, fornecer previsões mais precisas.

8. REFERÊNCIAS

- ALMEIDA, G. P. D.; SANTOS, H. P. D. Acoplamento oxidativo do metano como alternativa do uso do gás natural para a produção de eteno: uma revisão. Trabalho de conclusão de curso em Engenharia química na Universidade Federal de São Paulo - UNIFESP, São Paulo, Fevereiro 2022
- ALMEIDA, P. R., de ANDRADE, R. M., e de SOUZA, R. C.. Utilização de algoritmos de aprendizagem de máquina para predição e controle de parâmetros em processos de usinagem. *Revista Eletrônica Científica Inovação e Tecnologia*, 8(1), 1-10, 2020. <https://doi.org/10.33837/rict.v8i1.3115>
- ALVES S. C. Reforma a vapor do metano para produção de hidrogênio: estudo termodinâmico e protótipo de modelo matemático de reator com membrana. Tese de Mestrado. Universidade Federal de Uberlândia. Uberlândia, 2005
- ANDREWS, J. W. Hydrogen production and carbon sequestration by steam methane reforming and fracking with carbon dioxide. *International Journal of Hydrogen Energy*, v. 45, p. 9279-9284, 2020.
- ADENIYI, A. G.; IGHALO, J. O.; MARQUES, G. Utilisation of machine learning algorithms for the prediction of syngas composition from biomass bio-oil steam reforming. *International Journal of Sustainable Energy*, v. 40, p. 310-320, 2021.
- ARCE-MEDINA, G. Random Forests. In C. Sammut, G. I. Webb (Eds.), *Encyclopedia of Machine Learning*, pp. 792-794, 2009.
- BASU, P. Biomass Gasification, Pyrolysis and Torrefaction. *Practical Design and Theory*. Academic Press, 2nd edition, p. 530, 2013.
- BERNARDES, C.J.; Estudo da permeação de hidrogênio em reator com membrana de paládio: modelagem matemática e simulação computacional. Tese de Mestrado, Universidade Federal de Uberlândia. Uberlândia, 2009
- BHARADWAJ, S.S.; SCHMIDT, L. Olefins by Catalytic Oxidation of Alkenes in Fluidized-Bed reactors. *Journal of Catalysis*, 1995;
- CHAI, T.; DRAXIER, R. R. Root mean square error (RMSE) or mean absolute error (MAE)?. *Geoscientific Model Development Discussions*, v. 7, p. 1525-1534, 2014.
- CHEN, T.; GUESTRIN, C. XGBoost: A Scalable Tree Boosting System. *KDD '16*, San Francisco - CA, p. 13-17, 2016.
- CUTLER, A. Ensemble learning. In A. Cutler, A. Cutler (Eds.) *Encyclopedia of Machine Learning*, pp. 325-325, 2012.

DIEDERICH, J. Explanation and artificial neural networks, *Int. J. Man-Machine Studies* v. 37, p. 335-355, 1992.

EHSANI, M. R. ; BATENI, H. ; PARCHIKOLAEI, G. R. Modeling of Oxidative Coupling of Methane over Mn/Na₂WO₄/SiO₂ Catalyst Using Artificial Neural Network. *Iran. J. Chem. Eng* 32, n. 3, 2013.

FARRAUTO, R. J. Introduction to catalysis and industrial catalytic processes. John Wiley & Sons, 2016.

FEIGENBAUM, E. A. "A personal view of expert Systems: Looking back and looking ahead", Department of computer Science – Stanford University, 1992.

FROMENT, G.F.; BISCHOFF, K. B.; DE WILDE, J. Chemical Reactor Analysis and Design, 1990.

FROMENT, G. F.; XU, J. Methane steam reforming, methanation and water-gas shift: I. intrinsic kinetics. *AIChE Journal*, v. 35, n. 1, p. 88-96, 1989.

GASPAR, A.B., DIEGUEZ, L.C. "Dispersion stability and methylcyclopentane hydrogenolysis in Pd/Al₂O₃" *Applied Catalysis A: General*, v. 201, 241-251, 2000.

HASTIE, T., TIBSHIRANI, R., & FRIEDMAN, J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. Springer, 2019.

HAUKE, J., KOSSOWSKI, T. "Comparison of values of pearson's and spearman's correlations coefficients on the same sets of data.". *Quaestiones Geographicae* 30(2), Bogucki Wydawnictwo Naukowe, pp. 87–93, 3 figs, 1 table, 2011. DOI 10.2478/v10117-011-0021-1, ISBN 978-83-62662-62-3.

LEE, C. Feature Importance Measures for Tree Models - Part 1. Veritable, 2017.

LIN, Y.; LIU, S.; CHUANG, C.; CHU, Y.. Effect of incipient removal of hydrogen through palladium membrane on the conversion of methane steam reforming. experimental and modeling. *Catalysis Today*, v. 82, p. 127-139, 2003.

LUNSFORD, J. H. Catalytic conversion of methane to more useful chemicals and fuels: a challenge for the 21st century", *Catalysis Today* v.63, pp. 165-174, 2000.

MUNIZ, F. Acoplamento Oxidativo de Metano. [s.l.] Universidade Federal do Rio de Janeiro, 2007.

NISHIMURA, S.; OHYAMA, J.; KINOSHITA, T.; LE DINH, S.; TAKAHASHI, K. Revisiting Machine Learning Predictions for Oxidative Coupling of Methane (OCM) based on Literature Data. *ChemCatChem*, v. 12, p. 5888– 5892, 2020.

- QUININO, R. C.; REIS, E. A.; BESSEGATO, L. F. Using the Coefficient of Determination R^2 to Test the Significance of Multiple Linear Regression, *Teaching Statistics*, v. 35, p. 84-88, 2013.
- ROY, S. Economics and simulation of fluidized bed membrane reforming. *Int. J. Hydrogen Energy*, v. 23, n.9, p. 745- 752, 1998.
- SANTOS, P. V. M. D. Modelagem e simulação de um reator a membrana para produção de hidrogênio. Dissertação de Mestrado em Engenharia Química da Universidade Federal do Rio Grande do Norte (UFRN), Natal, Agosto 2019.
- SPALLINA, V. Techno-economic assessment of different routes for olefins production through the oxidative coupling of methane (OCM): Advances in benchmark technologies. *Energy Conversion and Management*, v. 154, p. 244– 261, 2017.
- SPEIGHT, J.; LOYALKA, S. ; SUNGGYU, L. *Handbook of Alternative Fuel Technologies*. Environmental Science, 2007.
- STANSCH, Z.; MLECZKO, L.; BAERNS, M.. Comprehensive Kinetics of Oxidative Coupling of Methane over the $\text{La}_2\text{O}_3/\text{CaO}$ Catalyst. *Industrial and Engineering Chemistry Research*, v. 36, n. 7, p. 2568–2579, 1997.
- TAKAHASHI, I.; K. MIYAZATO, NISHIMURA, S.; OHYAMA, J . Unveiling Hidden Catalysts for the Oxidative Coupling of Methane based on Combining Machine Learning with Literature Data. *ChemCatChem*, v.10, p.1-7, 2018. doi: 10.1002/cctc.201800310
- WANG, H.; CONG, Y.; YANG, W., “Oxidative coupling of methane in $\text{Ba}_{0.5}\text{Sr}_{0.5}\text{Co}_{0.8}\text{Fe}_{0.2}\text{O}_{3-\delta}$ tubular membrane reactors”, *Catalysis Today* v.104, pp. 160–167, 2005.
- WANG, W.; LU, Y. Analysis of the Mean Absolute Error (MAE) and the Root Mean Square Error (RMSE) in Assessing Rounding Model. *IOP Conference. Series.: Materials Science and Engineering*, 2018. doi: 10.1088/1757-899X/324/1/012049
- WARD, T. L.; DAO, T.: Model of hydrogen permeation behavior in palladium membranes. *J. Membr. Sci* 153, 211, 1999.
- WARNECKE, R., Gasification of biomass: comparison of fixed bed and fluidized bed gasifier. *Biomass and Bioenergy*, v.18, 2000.