



Pontifícia Universidade Católica
do Rio de Janeiro




Subverting the Conventional FDD Sequence: A Diagnosis-First Approach with Deep Learning

Defesa de doutorado
João Gonçalves Neto

Orientadores
Amanda L. T. Brandão
Karla Figueiredo
João B. P. Soares

Banca Examinadora
Andréa P. Parente
Manoela Kohler
Maurício Bezerra



Detecção e Diagnóstico de Falhas

Sistema em comportamento anômalo

Causa do comportamento anômalo

Intervenção antes de atingir um estado crítico

Evitar paradas não planejadas

Reduzir os custos de manutenção


Monitoramento de
variáveis de processo



Complexidade de processos industriais

- Sistemas multivariados, não-lineares e sequenciais
- Grandes volumes de informação simultânea
- Maior dificuldade para soluções mais clássicas

Soluções baseadas em
Machine Learning





1984 - Acidente de Bhopal - Índia

- Planta de pesticida - vazamento de Isocianato de Metila
- 3800 vítimas imediatas



2010 - Acidente Macondo (Deepwater Horizon) - Golfo do México

- Série de falhas nos sistemas de segurança - perda de controle do escoamento
- Derramamento de 5 milhões de barris de petróleo




Segurança de pessoas




Proteção do meio ambiente



**Redução de perdas financeiras
na Indústria**



- Detecção de falhas
- AE + LSTM
- Múltiplos blocos (diferentes variáveis)



- Diagnóstico de falhas
- 1D-CNN + 2D-CNN (Ensemble)
- Múltiplas representações de dados



- Diagnóstico de falhas
- Triage + CNN
- Séries temporais empilhadas

Principais tendências e desafios



Abordagens Encontradas na literatura

- Múltiplos modelos
- Válido como avaliação inicial
- Limitação por conta de recursos
- Não existe solução única

FDD na Indústria

Corr./lag de séries temporais

Complexidade dos processos

Escassez de dados falhados

Diagnóstico de Falhas

Falhas de mesma natureza

Diferentes dinâmicas entre falhas

Deteccção de Falhas

Agrupamento de falhas (uma classe)

Espaço de atributos inconsistente

Diagnóstico de Falhas

Investigar modelagem com feature learning

Propor uma abordagem DL mais focada

Otimizar uma única arquitetura

Detecção de Falhas

Propor um framework inovador


Reformular como similaridade

Explorar uso de transfer learning


Projeto Total

Avançar área de FDD com DL

Avaliar em benchmark e comparar



Processo Tennessee Eastman



Identificação	Descrição	Tipo
Falha 1	Razão de alimentação A/C, composição de B constante (corrente 4)	Degrau
Falha 2	Composição de B, razão de alimentação A/C constante (corrente 4)	Degrau
Falha 3	Temperatura da alimentação D (corrente 2)	Degrau
Falha 4	Temperatura de entrada da água de resfriamento do reator	Degrau
Falha 5	Temperatura de entrada da água de resfriamento do condensador	Degrau
Falha 6	Perda de alimentação de A (corrente 1)	Degrau
Falha 7	Perda de pressão em C — disponibilidade reduzida (corrente 4)	Degrau
Falha 8	Composição de alimentação de A, B e C (corrente 4)	Aleatório
Falha 9	Temperatura da alimentação D (corrente 2)	Aleatório
Falha 10	Temperatura da alimentação de C (corrente 4)	Aleatório
Falha 11	Temperatura de entrada da água de resfriamento do reator	Aleatório
Falha 12	Temperatura de entrada da água de resfriamento do condensador	Aleatório
Falha 13	Cinética da reação	Mudança gradual
Falha 14	Válvula da água de resfriamento do reator	Travamento
Falha 15	Válvula da água de resfriamento do condensador	Travamento
Falha 16	Desconhecido	Desconhecido
Falha 17	Desconhecido	Desconhecido
Falha 18	Desconhecido	Desconhecido
Falha 19	Desconhecido	Desconhecido
Falha 20	Desconhecido	Desconhecido

- Benchmark
- 52 variáveis de processo
- 20 falhas
- Treino e teste subsets
- Subgrupo de 5.250.000 amostras
- Fonte dos dados: Kaggle [39]



Capítulo 1: Diagnóstico

Pré-tratamento dos dados

5,250,000 amostras

Base original



20 amostras

Janela de observação

Sub-amostragem

Estratificada



36,000 janelas

Treinamento



9,000 janelas

Validação





5,000 janelas


Teste



Arquitetura - Rede Neural Convolucional



$$GASF_{i,j} = x_i \cdot x_j - \sqrt{1 - x_i^2} \cdot \sqrt{1 - x_j^2}$$




- **Bom para oscilações**
- **Perda de sinal ($\pm$)**
- **Informação diagonal**

- **CNN - Feature learning**
- **Desempenho próximo ao GASF-MSNN**

Etapas da investigação

Tipos de modificações

Taxas de decaimento LR e definição do modelo baseline



- Estratégia Holdout - Processamento apenas com CPU
- Teste do melhor modelo e comparação com a literatura

1

Rotação e
empilhamento
de matrizes

2

Qtd. filtros e
dim. de
kernels
(camada 1)


Tipo 1
+
Tipo 2

3


Qtd. filtros
em múltiplas
camadas

4

Impacto do decaimento da taxa de aprendizado




Modelo baseline ($k = 0.010$)



- **F1-score de validação: 81,93%**
- **Treino vs validação**

Modificações de tipo 1, 2 e 3 - F1-score de validação

Modificação de tipo 1



F1-score = 81.13%

Modificações de tipo 2

Parâmetro	kernel 3x3	kernel 5x5
64 filtros	82.35%	82.59%
128 filtros	82.93%	82.68%


Modificações de tipo 3 (tipo 1 + tipo 2)

Parâmetro	kernel 3x3	kernel 5x5
64 filtros	81.51%	56.67%
128 filtros	82.54%	47.89%

- Rotação não contribuiu para o aprendizado
- Casos 5x5 do tipo 3 com overfitting
- Aumento de filtros foi benéfico
- 3x3 vs 5x5 tipo 2 resultados próximos
- Mais parâmetros com 5x5
- Benefícios da informação vizinha
- 52 canais, mais filtros necessários

Modificações de tipo 4 - Validação


ID Modelo	Quantidade de filtros por camada convolucional					
	Conv 1	Conv 2	Conv 3	Conv 4	Conv 5	Conv 6
Model 1	64	128	128	128	256	—
Model 2	128	128	128	128	256	—
Model 3	256	128	128	128	256	—
Model 4	512	128	128	128	256	—
Model 5	1024	128	128	128	256	—
Model 6	2048	128	128	128	256	—
Model 7	1024	512	128	128	256	—
Model 8	1024	512	512	128	256	—
Model 9	1024	512	512	256	256	—
Model 10	1024	512	512	256	256	128
Model 11	1024	512	512	256	256	256




- O aumento de filtros teve efeito significativo
- Provável gargalo de informação na primeira camada

- Overfitting para camadas adicionais (Conv 6)
- Modelo 9 com maior desempenho

Modelo 9 - Avaliação do treinamento




F1-score da Validação




- **F1-score médio de validação: 89,40%**
- **Gap entre treino e validação (<5%)**
- **Maior dificuldade com falhas 3, 9, 10, 15, e 16**

Modelo 9 - Avaliação do treinamento



- **F1-score médio de validação: 89,40%**
- **Gap entre treino e validação (<5%)**
- **Maior dificuldade com falhas 3, 9, 10, 15, e 16**

F1-score do teste



Modelo 9 - Teste - Comparação com a literatura

F1-score	Nosso Modelo	Ref.1 ^a	Ref.2 ^b	Ref.3 ^c	Ref.4 ^d
Falha 1	99.60 %	94.67 %	100.0 %	99.81 %	100.0 %
Falha 2	100.0 %	96.63 %	100.0 %	99.40 %	99.80 %
Falha 3	72.47 %	24.62 %	N/A	96.98 %	58.00 %
Falha 4	98.81 %	99.87 %	99.00 %	99.97 %	100.0 %
Falha 5	99.80 %	94.67 %	89.00 %	93.87 %	80.30 %
Falha 6	100.0 %	99.30 %	90.00 %	99.46 %	100.0 %
Falha 7	100.0 %	97.50 %	99.00 %	100.0 %	100.0 %
Falha 8	97.55 %	73.61 %	82.00 %	98.45 %	75.40 %
Falha 9	41.73 %	27.45 %	N/A	87.59 %	0.00 %
Falha 10	75.74 %	53.84 %	77.00 %	98.61 %	94.20 %
Falha 11	98.17 %	99.29 %	99.00 %	99.40 %	99.90 %
Falha 12	98.40 %	83.99 %	83.00 %	97.83 %	86.70 %
Falha 13	96.95 %	60.52 %	57.00 %	98.41 %	87.80 %
Falha 14	100.0 %	99.94 %	100.0 %	99.62 %	85.80 %
Falha 15	53.31 %	25.22 %	N/A	83.50 %	0.40 %
Falha 16	75.58 %	80.74 %	77.00 %	N/A	1.00 %
Falha 17	97.13 %	97.92 %	99.00 %	N/A	97.90 %
Falha 18	97.14 %	84.13 %	81.00 %	N/A	84.20 %
Falha 19	98.99 %	96.42 %	99.00 %	N/A	99.80 %
Falha 20	95.67 %	69.49 %	95.00 %	N/A	98.00 %
F1-score médio	89.85 %	77.99 %	N/A	N/A	77.46 %

^aSum e Ren (2021) [2]; ^bRen *et al.* (2023) [52]; ^cTao *et al.* (2024) [51];

^dSouza *et al.* (2024) [50].

- Desempenho próximo a publicações recentes
- 7 falhas com valor equivalente ou maior
- Maior desempenho médio
- Maior dificuldade com falhas 3, 9, 10, 15 e 16
- Já são falhas conhecidas pela dificuldade

Desenvolvimento e avaliação de uma arquitetura GASF+CNN para diagnóstico de falhas no processo Tennessee Eastman.

O estudo resultou em modelo com desempenho equivalente ou superior a trabalhos recentes da literatura (89,85% de F1-score médio de teste).

Abordagem metodológica focada na investigação e aprimoramento de uma única arquitetura, importante a ser reforçado na literatura.



Capítulo 2: Detecção

Pré-tratamento dos dados

Inclusão apenas de casos normais

1



Séries de 20 amostras

2



Sorteio sem reposição

3



Sub-amostragem 1 do TEP



Séries base sorteadas



Entrada Modelo

Séries de 20 amostras

1



Exclusão de casos do diagnóstico

2



Sorteio sem reposição

3



Exclusão de séries base sorteadas

4



Balanceamento normal e falha

5



Sorteio estratificado de casos falhados

6



Rotulagem
0 > Normal
1 > Falhado

7



Sub-amostragem 2 do TEP



Séries "par" sorteadas



Treino : Validação : Teste

70.000 : 20.000 : 10.000






Etapas da investigação


Impacto da quantidade de dados

Definição do modelo baseline




Controle de overfitting

Congelamento de camadas convolucionais




Controle de underfitting

Ajuste de Dropout
Adição de camada densa
Congelamento progressivo





Avaliação final

Teste do melhor modelo
Avaliação de distribuição
Comparação com a literatura





Avaliação do tamanho do dataset de treinamento - Curvas de aprendizado





- Com early stopping
- Aprimoramento gradual após 7k
- Treinamento vs Validação
- Desempenho 20~40 épocas
- Possível parada prematura

Avaliação do tamanho do dataset de treinamento - Curvas de treinamento





- Desempenho primeira época
- Treinamento suave acima de 7k
- Validação ruidosa
- Parada prematura
- Reavaliar com 30 épocas

Avaliação do tamanho do dataset de treinamento - Curvas de aprendizado





- Sem early stopping (30 épocas)
- Diminuição de flutuações
- Redução - valores intermediários
- Maior desempenho com 70k

Avaliação do tamanho do dataset de treinamento - Curvas de treinamento



- Desempenho primeira época
- Treinamento suave acima de 7k
- Validação ruidosa no início
- Redução prematura de LR
- Termos de paciência de 10 e 15



Etapa 1 - Modelo base - Validação cruzada



Métrica	Treinamento	Validação
F1-Score (%)	93,99 ±0,93	83,85 ±2,92
Épocas	46,4 ±11,3	
Duração (h)	11,3 ±2,7	

- **Cenário de alto desempenho**
- **Variabilidade considerável**
- **Gap e instabilidade - validação**
- **Parada prematura (2, 3 e 4)**

Etapa 1 - Modelo base - Validação cruzada



Métrica	Treinamento	Validação
F1-Score (%)	93,99 ±0,93	83,85 ±2,92
Épocas	46,4 ±11,3	
Duração (h)	11,3 ±2,7	

- Parada prematura (2 e 4)
- *Fold 3* maior L2 norm
- 9.597.440 parâmetros treináveis
- Provável quadro de *overfitting*

Principais Resultados

INTRO




CAP. 1

CAP. 2

CONC

30

Etapa 2 - Congelamento completo camadas convolucionais



Métrica	Treinamento	Validação
F1-Score (%)	91,41 ± 0,12	90,84 ± 0,18
Épocas	65,2 ± 14,2	
Duração (h)	15,8 ± 3,5	

- Alto desempenho na 1ª época
- Alta consistência
- Controle de *overfitting*
- Baixa lenta a partir da 1ª época

Principais Resultados

INTRO




CAP. 1

CAP. 2

CONC

31


Etapa 2 - Congelamento completo camadas convolucionais



Métrica	Treinamento	Validação
F1-Score (%)	91,41 ± 0,12	90,84 ± 0,18
Épocas	65,2 ± 14,2	
Duração (h)	15,8 ± 3,5	

- **Folds 1 e 2** menos épocas
- "Navegação" do otimizador
- **263.168** parâmetros treináveis
- Provável quadro de *underfitting*

Etapa 3 - Estratégias de aprimoramento - Efeitos sobre a validação



- Modificações no dropout - Efeito negligenciável





- Adição de camada densa - leve redução (nº parâmetros)



- Congelamento progressivo de camadas convolucionais
 - Primeira camada - Grupo 1
 - Melhora progressiva a partir do Grupo 2 (vs *baseline*)
 - Grupo 4 - Maior desempenho
 - Balanço - complexidade do problema e do modelo
 - Última camada - Atributos mais abstratos
 - Melhor configuração dentro do estudo

Etapa 3 - Melhor caso - Validação cruzada



Métrica	Treinamento	Validação
F1-Score (%)	92,48 ± 0,49	91,38 ± 0,20
Épocas	44,8 ± 4,9	
Duração (h)	10,7 ± 1,1	

- **Baixa flutuação (escala)**
- **Convergência em menos épocas**
- **Convergência em menos tempo**

Principais Resultados

INTRO




CAP. 1

CAP. 2

CONC

34



Etapa 3 - Melhor caso - Validação cruzada



Métrica	Treinamento	Validação
F1-Score (%)	92,48 ± 0,49	91,38 ± 0,20
Épocas	44,8 ± 4,9	
Duração (h)	10,7 ± 1,1	

- Variação baixa e L2 norm
- 853.760 parâmetros treináveis
- Modelo consistente



Etapa 4 - Teste do melhor caso - *Holdout*




Métrica	Treinamento	Validação
F1-Score (%)	92,74	91,57
Épocas	44	
Duração (h)	8,8	

- **F1-score teste: 91,41%**
- **Resultados consistentes com VC**
- **Convergência em menos tempo**








Etapa 4 - Teste do melhor caso - Distribuição das previsões



Etapa 4 - Teste do melhor caso - Distribuição das previsões



Etapa 4 - Teste do melhor caso - Distribuição das previsões



Etapa 4 - Teste do melhor caso - Comparação com a literatura

FDR	Nosso Modelo	Ref.1 ^a	Ref.2 ^b	Ref.3 ^c
Falha 1	1.0000	0.9983	1.0000	0.998
Falha 2	1.0000	0.9767	0.9838	0.984
Falha 3	0.3911	0.9567	N/A	0.688
Falha 4	1.0000	1.0000	1.0000	0.998
Falha 5	1.0000	0.2633	1.0000	0.249
Falha 6	1.0000	1.0000	1.0000	1.000
Falha 7	1.0000	1.0000	1.0000	1.000
Falha 8	0.9959	0.9433	0.9813	0.981
Falha 9	0.1399	0.8850	N/A	0.418
Falha 10	0.8385	0.8833	0.8950	0.808
Falha 11	0.9958	0.9533	0.7888	0.993
Falha 12	0.9959	0.6467	0.9988	0.996
Falha 13	0.9562	0.8733	0.9525	0.941
Falha 14	1.0000	0.9967	1.0000	0.780
Falha 15	0.0075	0.9850	N/A	0.418
Falha 16	0.8618	0.6450	0.9263	0.893
Falha 17	0.9788	0.9233	0.9650	0.905
Falha 18	0.9014	0.7633	0.9038	0.903
Falha 19	0.9919	0.9817	0.9163	0.870
Falha 20	0.9291	0.7933	0.9100	0.905
FDR médio	0.8492	0.8734	N/A	0.836
Média sem falhas 3, 9, and 15	0.9674	0.8613	0.9542	0.894

^aMa *et al.* (2024) [84]; ^bHu *et al.* (2025) [85]; ^cDong *et al.* (2025) [86].

- Desempenho próximo a publicações recentes
- 13 falhas com valor equivalente ou maior
- Mesmas falhas de maior dificuldade que o diagnóstico
- Sem falhas 3, 9 e 15, maior desempenho médio
- Herança do transfer learning
- Já são falhas conhecidas pela dificuldade

Reformulação do problema de detecção de falhas para um problema de similaridade através de uma arquitetura SNN.

Aproveitamento dos padrões aprendidos pelo modelo de diagnóstico através de *transfer learning*.

Modelo consistente com desempenho próximo ou superior a outros trabalhos da literatura (91,41% de F1-score de teste).

Abordagem metodológica focada na investigação e aprimoramento de uma única arquitetura.

Duas abordagens complementares de Detecção e de Diagnóstico de falhas atingindo alto desempenho comparado com trabalhos da literatura.

Alternativa inovadora subvertendo a ordem convencional de desenvolvimento de soluções de FDD.

Espaço para outras investigações:

- **Aplicação da metodologia em outros benchmarks e processos com dados reais**
- **Modelo integrado de FDD através de um ensemble entre os modelos desenvolvidos**
- **Trabalhos focados nas falhas de maior dificuldade**
- **Exploração aprofundada de outro *backbone* para o modelo SNN**

Outras Publicações

INTRO

CAP. 1

CAP. 2

CONC

40

Participação em eventos



Avaliação do Programa de Recursos Humanos da ANP – 2024
Belo Horizonte, MG



**III SEMINÁRIO
DA
Pós-Graduação**
Rio de Janeiro, RJ - 2025



Projeto paralelo

Spectrochimica Acta Part A: Molecular and Biomolecular Spectroscopy 300 (2023) 122841



Framework for data-driven polymer characterization from infrared spectra

João G. Neto^a, Douglas A. Simon^b, Karla Figueiredo^c, Amanda L.T. Brandão^{a,*}

^a Department of Chemical and Materials Engineering, Pontifical Catholic University of Rio de Janeiro, Rio de Janeiro, 22451-900, RJ, Brazil

^b Federal Institute of Education, Science and Technology of Rio Grande do Sul, Farroupilha, 95174-274, RS, Brazil

^c Department of Informatics and Computer Science, Institute of Mathematics and Statistics, Rio de Janeiro State University, Rio de Janeiro, 20550-900, RJ, Brazil



REPÚBLICA FEDERATIVA DO BRASIL
MINISTÉRIO DO DESENVOLVIMENTO, INDÚSTRIA, COMÉRCIO E SERVIÇOS
INSTITUTO NACIONAL DA PROPRIEDADE INDUSTRIAL
DIRETORIA DE PATENTES, PROGRAMAS DE COMPUTADOR E TOPOGRAFIAS DE CIRCUITOS

Certificado de Registro de Programa de Computador

Processo Nº: **BR512024004445-0**

O Instituto Nacional da Propriedade Industrial expede o presente certificado de registro de programa de computador, válido por 50 anos a partir de 1º de janeiro subsequente à data de 26/05/2023, em conformidade com o §2º, art. 2º da Lei 9.609, de 19 de Fevereiro de 1998.

Título: Framework para Caracterização de Espectros Infravermelho de Polímeros usando Machine Learning

Data de publicação: 26/05/2023

- [2] S. Sun and J. Ren. GASF–MSNN: A New Fault Diagnosis Model for Spatiotemporal Information Extraction. *Industrial & Engineering Chemistry Research*, 60(17):6235–6248, 2021.
- [3] J. G. Neto, K. Figueiredo, J. B. P. Soares, and A. L. T. Brandão. Can Focusing on One Deep Learning Architecture Improve Fault Diagnosis Performance? *J. Chem. Inf. Model.* 65, 1289–1304, 2025.
- [23] K. F. A. Okada, A. S. de Moraes, and L. C. Ribeiro. A survey on fault detection and diagnosis methods. *14th IEEE International Conference on Industry Applications*, 1422–1429, 2021.
- [39] Tennessee Eastman Process Simulation Dataset. <https://www.kaggle.com/datasets/averkij/tennessee-eastman-process-simulation-dataset>, Accessed: 2022–07–28.
- [52] J. Ren, L. Tang e H. Zou. Comparative study of different data representations under CNN and a novel integrated FDD architecture. *The Canadian Journal of Chemical Engineering*, 101, 4571–4586, 2023.
- [50] A. C. O. Souza, M. B. Jr. de Souza e F. V. da Silva. Enhancing fault detection and diagnosis systems for a chemical process: a study on convolutional neural networks and transfer learning. *Evolv. Syst.*, 15, 611–633, 2024.
- [51] Q. Tao, B. Xin, Y. Zhang, H. Jin, Q. Li, Z. Dai e Y. Dai. A novel triage-based fault diagnosis method for chemical process. *Process Safety and Environmental Protection*, 183, 1102–1116, 2024.
- [73] C. Jin, F. Ma, J. Wang, and W. Sun. Fault detection for industrial chemical production using Siamese autoencoder. *IFAC-PapersOnLine*, 58(14):823–828, 2024.
- [84] F. Ma, C. Ji, J. Wang, W. Sun, X. Tang e Z. Jiang. MOLA: Enhancing Industrial Process Monitoring Using a Multi-Block Orthogonal Long Short-Term Memory Autoencoder. *Processes*, 12, 2824, 2024.
- [85] G. Hu, C. Tong, J. Zeng e L. Luo. Joint time–serial variation analysis for fault monitoring of chemical processes. *Process Safety and Environmental Protection*, 196, 106867, 2025.
- [86] J. Dong, D. Li, Z. Cong e K. Peng. A new fault detection method based on an updatable hybrid model for hard-to-detect faults in nonstationary processes. *Reliability Engineering & System Safety*, 259, 110920, 2025.

Agradecimentos

INTRO

CAP. 1

CAP. 2

CONC

42





Pontifícia Universidade Católica
do Rio de Janeiro



Subverting the Conventional FDD Sequence: A Diagnosis-First Approach with Deep Learning

Defesa de doutorado
João Gonçalves Neto

Orientadores
Amanda L. T. Brandão
Karla Figueiredo
João B. P. Soares

Banca Examinadora
Andréa P. Parente
Manoela Kohler
Maurício Bezerra